

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için

Hastalık Tespiti Kategorisi)

PROJE DETAY RAPORU

TAKIM ADI: METEoRS

TAKIM ID: 380975

İçindekiler Tablosu

1. Proje Mevcut Durum Değerlendirmesi	1
2. Özgünlük	4
3. Sonuçlar ve İnceleme	6
4. Deney ve eğitim aşamalarında kullanılan veri setleri	9
5. Referanslar	10



1. Proje Mevcut Durum Değerlendirmesi (20 puan)

Proje Sunuş Raporu tesliminden sonra gelecek aşamalarda kullanılacak teknolojiler üzerinde detaylı araştırma sürecine geçiş yapılmıştır. Takım üyeleri olarak veri ön işleme ve model geliştirme konularına odaklanılmıştır. Kısıtlı zaman dilimi içerisinde çalışmanın verimli olabilmesi için her bir takım üyesi bir konu üzerinde yoğunlaşmıştır. Bu konular veri ön işleme (data preprocessing), veri artırma (data augmentation), Convolutional Neural Network (CNN) tabanlı derin öğrenme modelleri oluşturmak için kütüphaneler, Compute Unified Device Architecture (CUDA), Google Colab ortamıdır. Her bir takım üyemiz özverili çalışma sonucunda diğer takım üyelerine yoğunlaştığı konu üzerindeki araştırmalarını sunmuştur.

Yarışma kapsamında kullanılacak veri seti paylaşılan kadar benzer problemlerin çözümü için kullanılan veri setleri üzerinde çalışmalar yapılmıştır. Abdomen bölgesi için internet üzerinde yeterli kaynak bulunmaması sebebiyle örnek çalışmalarda kullanılmak üzere Kaggle’da bulunan “Brain MRI Images for Brain Tumor Detection” başlıklı veri seti alınmıştır [1]. Veri setinde tümör var-yok şeklinde etiketli toplam 253 MR görüntüsü bulunmaktadır. Bu veri seti üzerinden veri ön işleme konusunda yeniden boyutlandırma (resize), boyut azaltma (dimensionality reduction), gri tonlama (grayscale), görüntü ölçekleme (scaling), normalleştirme (normalization) ve standartlaştırma (standardization) işlemleri için OpenCv ve Scimage kütüphaneleri kullanılarak örnekler yapılmıştır [2]. Veri artırma (image augmentation) konusunda aynı veriler üzerinde görüntü kaydırma (shift augmentation), görüntü çevirme (flip augmentation), parlaklık değiştirme (brightness augmentation), yakınlaştırma (zoom augmentation) işlemleri için Keras kütüphanesi kullanılarak örnekler yapılmıştır [3]. Bu kütüphanelerden yaygın kullanılan ve multi classification problemine özgü çözümde kullanılabilecek tensorflow ve keras kütüphaneleri üzerinde yoğunlaşmıştır [4]. Söz konusu kütüphaneler kullanılarak örnek veri seti üzerinde CNN modelinin kurulması, modelin eğitilmesi ve modelin test edilmesi çalışmaları yapılmıştır [5, 6].

Model eğitiminde GPU kullanımı beraberinde CUDA mimarisinin de kurulumu gerçekleştirilip performans ölçümü yapılmıştır. Yapılan deneyler sonucunda CUDA mimarisi kullanılarak oluşturulan modelin daha hızlı ve performans açısından daha verimli olduğu görülmüştür.

Epoch	gpu_mem	box	obj	cls	labels	img_size	
0/127	6.28G	0.1182	0.01322	0.03284	26	512:	0% 8/1637 [00:16<45:14, 1.67s/it]

Şekil 1. GPU kullanılarak modelin performans ölçümü

Epoch	gpu_mem	box	obj	cls	labels	img_size	
174/299	7.14G	0.02514	0.00431	0.001064	21	512:	7% 141/2046 [00:41<09:16, 3.42it/s]

Şekil 2. CUDA mimarisi kullanılarak modelin performans ölçümü

Yapay zekâ ve derin öğrenme projeleri üzerinde çalışmak için etkileşimli, tamamen bulut tabanlı, bir programlama ortamı olan Google Collaboratory, ücretsiz olması, kurulum gerektirmemesi, kullanımı kolay ve ortak çalışmaya dayalı olmasından dolayı tercih edilerek takım üyelerimiz ile bu platform üzerinde yukarıda bahsedilen konularda geliştirmeler yapılmıştır [7].

Proje Sunuş Raporu hakem değerlendirmesi açıklandıktan sonra hakemler tarafından yapılan geri dönüşler özenle incelenmiştir. Bu incelemeler sonucunda çeşitli görüntüleme tekniklerine rağmen kısıtlı sayıda tekniklerin araştırıldığı ve bu durum tekrar ele alınarak farklı görüntüleme

tekniklerinin de dahil olduğu çalışmaların bulunması planlanmıştır. Literatür araştırmaları sonucu bulunan çalışmalarda abdominal bölgesi üzerine yapılan benzer bir çalışma bulunamamış, projedeki probleme benzer nitelikte bulunan çalışmaların X-ray görüntüleri kullanılarak göğüs bölgesinde yapıldığı görülmüştür.

Proje Sunuş Raporu sonuçları açıklanmadan önce ve sonra danışman hocamızla görüşmelere ek olarak alanında uzman, yapay zekâ üzerinde çalışmalar yapmış öğretim üyeleri ve derin öğrenme üzerine çalışan girişim sahipleri ile görüşülmüştür. Görüşülen kişiler arasında Doç. Dr. Yusuf Yalçın İleri, Dr. Öğr. Üyesi Muhammed Usame Öziç, Doç. Dr. Şebnem Özdemir, Prof. Dr. Barkın İlhan, Dr. Öğr. Üyesi Ayşe Merve Acılar, Gülhan Ertürk Akgül ve Tansel Akgül yer almaktadır. Bu görüşmelerde abdominal bölge için verilere olan bakış açısı, verilerin ön işlenmesi, gerekli olma durumunda sentetik veri üretilmesi veya verilerin çoğaltılması, modelde kullanılacak mimari ve algoritmalara ayrıntılı olarak değinilmiştir. Yapılan görüşmeler ve araştırmalar, veriler üzerinde çalışma, ön işleme, model oluşturma ve geliştirme aşamaları için katkı sağlamıştır.

Probleme özgü çözümde kullanılacak görüntülerin kırpılarak vücut dışında kalan kısımların atılabileceği, verilerin yetersiz kalması durumunda sentetik veri üretimiyle literatüre farklı bir yönde katkı sağlanabileceği, veriler üzerinde klasik ön işleme yapılarak projeye özgünlük kazandırabileceği tavsiyeleri alınmıştır. Görüşmeler sonucunda probleme özgü çözümde ise Faster R-CNN ve YOLOv5 modelleri kullanılmasına karar verilmiştir. Bu algoritmaların desteklediği görüntü formatlarının araştırılması ve karşılaştırılması önerilmiştir.

2. Özgünlük (30 puan)

Modelin; algoritmasının güncel, deneysel çalışmaların sonucuna göre daha hızlı ve başarılı, birçok platforma uyumlu ve taşınabilir, optimize edilmiş, dinamik olması özelliklerindendir. Tüm bu özelliklerin sağlanması için izlenen adımlar aşağıda detaylı bir şekilde açıklanmıştır.

Verilerle birlikte paylaşılan excel dosyası, örnek görüntüler klasörü ile birlikte incelenmiştir. Yapılan incelemelere göre tip sütununda “BB” değeri olan kesitlerin hastalıklı kesit olduğu görülmüştür. Bu bilgiler bir kez python sözlük veri yapısına aktarılmış ve bu sözlük üzerinden işlem yapılarak zaman karmaşıklığı azaltılmıştır. İlk olarak hastalıklı kesitler sözlük veri yapısındaki hastalık sınıflarına göre ayrılmış ardından her sınıfa özgü bir klasör oluşturulup, görüntüler bu klasörlerin içerisine aktarılmıştır. Görüntüler klasörlere aktarılırken ön işleme aşamalarından (standartlaştırma, yeniden ölçeklendirme, pencereleme ve kontrast artırma) geçirilmiş ve dinamik olarak dosya formatı değişikliği yapılmıştır. YOLOv5 ile oluşturulacak modelde dicom formatından, desteklenen ve seçilmiş görüntü formatlarına (png, tif ve bmp) dönüşüm yapılmış, model skoruna olan etkileri analiz edilmiştir.

Dinamik olarak alınan hastalıklı kesitler için verilen minimum bounding box koordinat değerlerinden merkez, genişlik ve yükseklik değerleri bulunmuştur. YOLOv5 modeli için txt dosyasına yazılacak bu koordinat değerleri (x, y, yükseklik, genişlik) 0-1 aralığında olması gerektiğinden değerler normalize edilerek bu aralığa getirilmiştir. Normalizasyon işlemi Şekil 3'te gösterilen formül yardımıyla gerçekleştirilmiştir.


```

for i in x_y_coordinates:
    left,top, right,bottom = [int(i[0]),int(i[1]),int(i[2]),int(i[3])]
    widtht = right - left #Genişlik değerinin bulunması
    height = bottom - top #Yükseklik değerinin bulunması
    xc = (left + right) / 2 #Merkez noktasının x Değeri
    yc = (top + bottom) / 2 #Merkez noktasının y Değeri

    widtht = widtht / ds.Rows #Genişlik değerinin orijinal dicom görüntüsünün satır sayısına bölünmesi
    xc = xc / ds.Rows #Xc değerinin orijinal dicom görüntüsünün satır sayısına bölünmesi

    height = height / ds.Columns #Genişlik değerinin orijinal dicom görüntüsünün sütun sayısına bölünmesi
    yc = yc / ds.Columns #Yc değerinin orijinal dicom görüntüsünün sütun sayısına bölünmesi

```

Şekil 3. Normalizasyon işlemi için kod parçacığı

Çalışmaya ait, çeşitli özellikler değiştirilerek farklı modeller oluşturulmuş ve f1 skor üzerindeki etkileri gözlemlenmiştir. Amaç, en yüksek f1 skor değerine sahip model yapısının bulunmasıdır. Bu özelliklerden başlıcaları görüntülerin dosya formatı, verinin train, validation, test olarak ayrılma oranı; fine tuning, cache, evolve parametrelerinin kullanımı; batch size, epoch sayısı ve optimizasyon algoritmasıdır. Ek olarak lr0, lr1, momentum için hiper parametrelerin analizleri gerçekleştirilmiştir. Bu araştırmalar sonucunda, model doğruluğunun değişimi analiz edilerek optimum durumu veren kombinasyon elde edilmeye çalışılmıştır. Elde edilen kombinasyon değerleri Tablo 1’de sunulmuştur.

Tablo 1. Probleme Özgü Geliştirilen Optimum Modelin Özellikleri

Özellik	Değeri
Dosya formatı	BMP
Veri seti dağılımı*	Her bir sınıf için >1500 train/val Toplam >10000 train/val
Batch size **	-1
Epoch size	300
Optimizer	SGD
lr0	0.01
lr1	0.1
Momentum	0.937


*%70 train, %15 validation, %15 test değerinde tüm sınıflar için mAP değeri: 0.80

**Batch size parametresi için -1 değeri, model eğitim sırasında bellek kullanım miktarını otomatik olarak belirlemektedir [8].

Optimizasyon algoritması olarak Adam, AdamW ve Stokastik Gradient Descent (SGD) denenmiştir. Yapılan literatür araştırmaları sonucu, AdamW algoritmasının model eğitimi sonrası fine tuning kullanımının, SGD algoritmasına kıyasla daha yüksek skor verdiği bilgisi edinilmiştir [9], fakat deneysel çalışmalar sonucu aynı şartlar altında eğitilen iki algoritma için SGD’nin daha başarılı olmasından dolayı optimizasyon algoritması olarak Tablo 1’deki modelde SGD kullanılmıştır.

Sonuçlar ve inceleme başlığı altında detaylı olarak incelenen fine tuning kullanımının modelin tahmin etme başarısını (precision) arttırdığı görülmüştür. Bu nedenle yapılan deneysel çalışmalarda fine tuning uygulanmıştır.

Oluşturulan modelde, frameworkler ve donanım mimarileri arasındaki bağımlılığı ortadan kaldırmak, taşınabilirlik ve birlikte çalışabilirliği sağlamak için Open Neural Network Exchange (ONNX) formatı kullanılmıştır [10]. Bu sayede modelin çapraz platformlarda çalışabilir hale gelmesi sağlanmıştır. Böylelikle ONNX formatı ile diğer platformlara taşınan modelin tekrar eğitimine gerek kalmadığından eğitim sürecinin maliyeti ortadan kaldırılmıştır. Bu format sayesinde modelin arka planda çalışan katmanlarının incelenebilecek bir arayüz elde edilmiştir.




Şekil 4. Onnx Uygulanarak Görüntülenen YOLO Mimarisi Katmanları

Tüm bu yapılan işlemlere ek olarak toplu modelleme (model ensembling) üzerine çalışılmıştır. Toplu modelleme birçok farklı modelleme algoritması kullanarak ya da farklı eğitim veri setleri kullanarak bir sonucu tahmin etmek için çok çeşitli modellerin oluşturulduğu bir işlemdir [11]. Bu çalışmada belirtilmiş modeller, 6 farklı hastalık sınıfı için eğitilmiş olup toplu modellemenin etkisini ölçmek amacıyla bu modellere ek olarak her bir sınıf için ayrı ayrı eğitilmiş modellerin çıktıları alınacaktır. Yarışmanın bir sonraki aşaması için edinilen bilgiler ışığında model başarısını arttırmak amacıyla eğitilmiş farklı modeller üzerinde hibritleştirme denemeleri yapılacaktır.

3. Sonuçlar ve İnceleme (30 puan)

Yapılan araştırmalar, verilen probleme olan uygunluğu ve uzmanlarla yapılan görüşmeler sonucunda Faster R-CNN ve YOLOv5 modelleri, medikal görüntülerde kullanılması sebebiyle U-Net mimarisi üzerinde çalışılmıştır. U-Net mimarisi object detection yerine segmentasyon işlemi yaptığından dolayı tercih edilmemiştir [12, 13]. Paylaşılan veri seti üzerinde Faster R-CNN ve YOLOv5 modelleri denenmiştir. Test verileri üzerinde yapılan denemeler sonucunda elde edilen başarı oranının daha yüksek olması sebebiyle çalışmalara YOLOv5 algoritması üzerinden devam edilmiştir.

YOLOv5, sinir ağı üzerinden yalnızca bir ileri yayılım çalıştırıldıktan sonra tahminlerde bulunur. Görüntünün tamamını işlemek için tek bir sinir ağı kullanır, ardından görüntüyü ızgaralara böler. ızgaradaki her parça, kendi içindeki nesneleri algılamaktan sorumludur ayrıca bounding box ve nesnelerin olasılıklarını tahmin eder. Bounding box'lar, beklenen olasılığa göre ağırlıklandırılır. Aktivasyon fonksiyonu olarak gizli katmanlarda Leaky ReLU veya sigmoid kullanır. Optimizasyon algoritması olarak SGD, Adam, AdamW kullanılabilir, varsayılan algoritması ise SGD'dir [14]. YOLOv5 kullanıcılarına problemlerinin çözümlerine göre n, s, m, l ve x olmak üzere 5 farklı boyutta model sunmaktadır [15].




Şekil 5. YOLOv5 modelleri

Bu modellerin her biri Şekil 5'te görüldüğü gibi farklı tespit doğruluk değeri ve performansı sunmaktadır [16].

Model	size (pixels)	mAP _{val} 0.5:0.95	mAP _{val} 0.5	Speed CPU b1 (ms)	Speed V100 b1 (ms)	Speed V100 b32 (ms)	params (M)	FLOPs @640 (B)
YOLOv5n	640	28.0	45.7	45	6.3	0.6	1.9	4.5
YOLOv5s	640	37.4	56.8	98	6.4	0.9	7.2	16.5
YOLOv5m	640	45.4	64.1	224	8.2	1.7	21.2	49.0
YOLOv5l	640	49.0	67.3	430	10.1	2.7	46.5	109.1
YOLOv5x	640	50.7	68.9	766	12.1	4.8	86.7	205.7

Şekil 6. YOLOv5 modelleri ve sundukları farklı doğruluk değerleri

Şekil 6'da görülen tabloda YOLOv5x, diğer 4 modele göre daha yavaştır. Ayrıca daha çok parametreye sahip olmasına rağmen en yüksek mAP değerine ulaştığı ve projedeki problem çözümünde daha hassas tahminler yapabilmek için tercih edilmiştir.



Şekil 7. Yolov5 modeli mimarisi

YOLOv5 tek aşamalı bir nesne detektörü olduğundan, diğer tüm tek aşamalı nesne detektörleri gibi üç önemli parçaya sahiptir.

1. **Model backbone:** Bu özellik, tekrarlayan gradyan bilgisini çözer ve gradyan değişimini, çıkarım hızını azaltan, doğruluğu artıran ve parametreleri azaltarak model boyutunu küçülten özellik haritasına entegre eder.

2. **Model neck:** Bilgi akışını artırmak için yol toplama ağını (PANet) kullanır. Modeldeki düşük seviyeli özelliklerin yayılmasını iyileştirir. PANet, nesnenin yerelleştirme doğruluğunu artıran alt katmanlardaki yerelleştirmeyi iyileştirir.
3. **Model head:** Modeldeki küçükten büyüğe nesnelerin tahminini verimli bir şekilde geliştirmeye yardımcı olur [17].


Yapılan deneysel çalışmalarda farklı görüntü formatları, batch size, epoch, optimizasyon algoritmaları, fine tuning uygulanma durumları uygulanarak birbirinden farklı modeller elde edilmiştir. Elde edilen modeller birbiriyle karşılaştırılıp analiz edilmiştir. Bu analiz sonuçları Tablo 2’de detaylı olarak gösterilmiştir.

Tablo 2. Farklı parametrelerin denenmiş kombinasyonları ve skorları


Model Numarası	Görüntü Formatı	Batch-Size	Epoch	Optimizer	Fine-Tuning	mAP Değeri	F1 Score (min -max)*
1	PNG	8	50	SGD	×	0.6116	0.134- 0.62
2	PNG	-1	50	SGD	×	0.8861	0.309- 0.88
3	TIF	-1	50	SGD	✓	0.7838	0.291- 0.81
4	TIF	-1	100	SGD	✓	0.8982	0.608- 0.87
5	TIF	-1	100	AdamW	×	0.5204	0.26- 0.53
6	BMP	-1	50	SGD	✓	0.6201	0.338- 0.66
7	BMP	-1	100	AdamW	✓	0.7599	0.325- 0.74
8	BMP	-1	100	SGD	×	0.7001	0.216- 0.71

*Verilen min, max değerleri tüm sınıflar arasından test etme süresini azaltmak amacıyla küçük boyutlu veri setiyle denenilen en düşük ve en yüksek F1 skorlarını temsil etmektedir.

Şekil 8 ve 9’da bulunan karmaşıklık matrislerinde, Tablo 2’de denenilen 4. modelin eğitim sonrası fine tuning işlemi uygulanmış ve uygulanmamış halinin sınıflandırma başarısına etkisi net bir şekilde görülmüştür.




Şekil 8. Fine tuning öncesi karmaşıklık matrisi [18] *




Şekil 9, Fine tuning sonrası karmaşıklık matrisi [19] *

*Karmaşıklık matrisleri üzerindeki değerler okunamadığından üzerinde değişiklik yapılarak sunulmuştur, orijinal halleri kaynakçada verilen drive dosyasında paylaşılmıştır.

AdamW ve SGD optimizasyon algoritmaları ile denenen iki farklı model optimizasyon algoritmaları ile denenmiştir ve sonuçlarının karşılaştırılması aşağıdaki grafiklerde verilmiştir. SGD optimizasyon algoritmasının daha iyi sonuç verdiği görülmüştür.




Şekil 10. AdamW optimizesi



Şekil 11. SGD optimizesi

Sonuç olarak modele uygulanan fine tuning işlemi, doğru optimizasyon algoritmasının seçimi, uygun dosya formatı, optimum epoch ve batch değeri gibi modeli etkileyecek özelliklerin seçimine bu başlık altında gösterildiği üzere karar verilmiştir. Optimizasyon algoritması olarak SGD, dosya formatı olarak Bmp, 300 epoch sayısına sahip olan modelin %80 mAP değeri ile şu an için optimum model olduğu sonucuna varılmıştır. Ayrıca oluşturulan model, farklı platformlarda da çalışabilmesi için ONNX formatına dönüştürülmüştür. Yarışma finaline kadar olan süreçte modelin daha başarılı sonuçlar elde etmesi için hiper parametre ve özellik dene-melerine özveri ile devam edilecektir.



Şekil 12. Optimum model ile tahmin edilen hastalıkların minimum bounding box ile görüntülenmesi*

*Verilen resimlerde 1 – Apandiks iltihabı (akut apandisit), 2 – Safra kesesi iltihabı (akut kolesistit), 3 – Pankreas iltihabı (akut pankreatit), 4 – Böbrek/üreter taşı, 5 – Bağırsak divertikül iltihabı (akut divertikülit), 6 – Karın ana damar balonlaşması/yırtılmasını temsil etmektedir.

4. Deney ve eğitim aşamalarında kullanılan veri setleri (15 puan)

Sağlık Bakanlığı tarafından sağlanan veri setine ek olarak başka bir veri seti kullanılmamıştır. Paylaşılan veri setinde toplam 1182 hastaya ait veri bulunmaktadır. Veriler detaylı olarak incelendiğinde hastalara ait serilerde bulunan hastalıklı kesit sayısı 29918 olarak bulunmuştur. Bu hastalıklar bulunduğu organlarla Tablo 3’te gösterilen şekilde eşleşmektedir.

Tablo 3. Paylaşılan verisetinde bulunan hastalıklar ve bulunduğu organlarla eşleşmesi

Label	Organ	Eşleşen Hastalık
1	Apandiks	Akut apandisit ile uyumlu, Apendikolit
2	Safra Kesesi	Safra kesesi taşı, Akut kolesistit ile uyumlu
3	Pankreas	Akut pankreatit ile uyumlu
4	Böbrek-Mesane	Böbrek Taşı, Üreter taşı
5	Kolon	Akut diverkült ile uyumlu, Kalsifiye divertikül
6	Abdominal Aorta	Abdominal aort anevrizma, Abdominal aort diseksiyon

6 farklı organda 11 farklı hastalık türü bulunmaktadır. Dicom görüntülerinde hastalıkların etiketleme işlemi yapılırken verilerle birlikte paylaşılan excel dosyasından her seferinde veri çekmek yerine, veriler bir python sözlük veri yapısı içine alınıp hastalıkların etiketleme işlemleri yapılmaktadır.

Abdomen bölgesinde bulunan hastalıklı kesit görüntüleri modele verilmeden önce ön işleme aşamasından geçmiştir. Ön işlemede kullanılan Python-Pydicom kütüphanesi dicom dosyaları üzerinde kolay bir şekilde okuma, yazma ve diğer işlemleri yapabilmeyi sağlar [20]. Bu kütüphane kullanılarak kesitler üzerinde bütün verilerin model tarafından aynı şekilde değerlendirilip eşit etkiye sahip olması amacıyla normalizasyon [21], önemli özelliklerin (feature) daha görünür hale getirilmesi ve hastalık tespitinin daha kolay yapılması amacıyla

pencereleme, eğitimin daha kısa sürmesi ve verilerin aynı boyuta getirilmesi amacıyla yeniden ölçeklendirme, nesne tespiti için daha görünür olması amacıyla kontrast artırma işlemleri gerçekleştirilmiştir. Dicom formatındaki görüntülerden hastalık içeren organların bulunduğu kesit bilgileri okunup Computed Tomography (CT) görüntülerinin arasından çekilen modelin eğitimde kullanılmayacak göğüs, akciğer, bacak, kol gibi eğitim için gürültülü bölgelerin ayrıştırılması dinamik olarak sağlanmıştır.

YOLOv5 modelinde desteklenen dosya formatları arasında dicom görüntüleri bulunmadığından görüntülerin farklı bir dosya tipine dönüştürülmesi gerektiği görülmüştür. Model denemelerinde hastalıklı kesitler 3 boyutlu dicom formatından 2 boyutlu yüksek kaliteli dijital görüntüleri görüntülemek için kullanılan portable network graphic (png) formatına dönüştürülmüştür. Aynı zamanda png formatına çevrilen dosyalar 512x512 boyutuna getirilip, hastalıklı kesitlerin koordinatları text dosyasına aktarılmıştır.

Png dosya formatı veriler üzerinde kullanıldığında sıkıştırma miktarı fazla olduğundan veri kaybı olabileceği için YOLOv5'in desteklediği diğer resim formatları incelenmiştir. Tif ve bmp resim formatları daha yüksek görüntü kalitesi sunması açısından bu dosya formatları üzerinde denemeler yapılmıştır. Yapılan deneysel çalışmada bmp formatı ile model üzerinde daha yüksek ölçüm skoru elde edildiği görülmüştür ve model için bu format üzerinden devam edilmiştir [22, 23].

5. Referanslar (5 puan)

Aqsa Mohiyuddin, Asma Basharat, Usman Ghani, Veselý Peter, Sidra Abbas, Osama Bin Naeem, and Muhammad Rizwan (2022). Breast Tumor Detection and Classification in Mam-mogram Images Using Modified YOLOv5 Network. <https://doi.org/10.1155/2022/1359019>

Olaf Ronneberger , Philipp Fischer , Thomas Brox (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. <https://doi.org/10.48550/arXiv.1505.04597>

<https://towardsdatascience.com/yolov5-compared-to-faster-rcnn-who-wins-a771cd6c9fb4>

IZA SAZANITA ISA 1, (Member, IEEE), MOHAMED SYAZWAN ASYRAF ROSLI 1 , UMI KALSOM YUSOF 2 , MOHD IKMAL FITRI MARUZUKI 1 , (Member, IEEE), AND SITI NORAINI SULAIMAN 1 (2022).Optimizing The Hyperparameter Tuning Of Yolov5 For Underwater Detection.10.1109/ACCESS.2022.3174583

Bohan Wei; Yao Zhang; Yufan Pu; Yiliang Sun; Shihan Zhang; Hongyu Lin; Changfan Zeng; Yahui Zhao; Kejun Wang; Zhiyong Chen(2022).Recursive-YOLOv5 Network for Edible Mushroom Detection in Scenes With Vertical Stick Placement.10.1109/ACCESS.2022.3165160

<https://github.com/ultralytics/yolov5>

[1]<https://www.kaggle.com/datasets/navoneel/brain-mri-images-for-brain-tumor-detection?resource=download>

[2]https://colab.research.google.com/drive/17cid-3Ye-iBs5XCrLmjT36eJV_dQ_mcWq?usp=sharing

[3] <https://colab.research.google.com/drive/1VtAe9IPG8V5zFK-EQxvrUue4hcb6LYUA>

[4]<https://statisticsanddata.org/data/most-popular-machine-learning-libraries/>

- [5]https://colab.research.google.com/drive/1Og63Sfk93pVdKFHWb1QZEyS8vbNF-ZIWx#scrollTo=SL94vrrE_F0E
- [6]https://colab.research.google.com/drive/1cB6EaN-7_Jjso99BYdBf2bRZB5ci-EPva?usp=sharing
- [7][https://globalaihub.com/blog/google-colab-nedir-ve-nasil-kullanilir/#:~:text=Google%20Colab%20\(Google%20Colaboratory\)%2C,senesinde%20Google%20ta-raf%C4%B1ndan%20piyasaya%20s%C3%BCr%C3%BCld%C3%BC](https://globalaihub.com/blog/google-colab-nedir-ve-nasil-kullanilir/#:~:text=Google%20Colab%20(Google%20Colaboratory)%2C,senesinde%20Google%20ta-raf%C4%B1ndan%20piyasaya%20s%C3%BCr%C3%BCld%C3%BC)
- [8]<https://medium.com/deep-learning-turkiye/derin-ogrenme-uygulamalarinda-en-sik-kullanilan-hiper-parametreler-ece8e9125c4#:~:text=Batch%20size%20genelde%2064ile%20512,Yani%20batch%20gradyan%20hesaplamas%C4%B1%20yap%C4%B1labilir.>
- [9]<https://medium.com/geekculture/a-2021-guide-to-improving-cnns-optimizers-adam-vs-sgd-495848ac6008>
- [10] <https://analyticsindiamag.com/onnx-standard-and-its-significance-for-data-scientists/>
- [11] <https://github.com/ultralytics/yolov5/issues/318>
- [12]<https://ayyucekizrak.medium.com/g%C3%B6r%C3%BCnt%C3%BCb%C3%B6l%C3%BCtleme-segmentasyon-i%C3%A7in-derin-%C3%B6l%C4%9Frenme-u-net-3340be23096b>
- [13]<https://jean-charles-nigretto.medium.com/advantages-of-u-net-for-image-segmentation-8ce869d28b4d>
- [14] <https://medium.com/@akdenizz7/yolov5-ile-nesne-tespiti-8aa370febfc0>
- [15] <https://learnopencv.com/custom-object-detection-training-using-yolov5/>
- [16] <https://www.mdpi.com/1424-8220/22/2/464/htm>
- [17]<https://deryacakmak.medium.com/yolov4-ve-yolov5-9c4ad208579e#:~:text=YOLOv5%2C%20di%C4%9Fer%20YOLO%20versiyonlar%C4%B1ndan%20farkl%C4%B1,Leaky%20ReLU%20ve%20Sigmoid%20kullan%C4%B1l%C4%B1r>
- [18]<https://drive.google.com/file/d/1xQuVVZXbEtOtMIiCORdPKKCvukDEeHFB/view?usp=sharing>
- [19]<https://drive.google.com/file/d/1Ja0cPmi7LDEXluQRieyq4mFM85zjiWxb/view?usp=sharing>
- [20] <https://pypi.org/project/pydicom/>
- [21] A., Yüce, H., & Özkan, A. O. (2021). Normalizasyon Yöntemlerinin Biyomedikal Verilerde Sınıflandırma Performansına Etkisi. European Journal of Science and Technology Special Issue, 30, 35–43. <https://doi.org/10.31590/ejosat.1011723>
- [22]<https://medium.com/hd-pro/jpeg-tiff-png-svg-file-formats-and-when-to-use-them-1b2cde4074d3#:~:text=When%20printing%20or%20publishing%20commercial,SVG%20is%20the%20preferred%20format>
- [23] <http://www.differencebetween.info/difference-between-tiff-and-png>