

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

**(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için Hastalık
Tespiti Kategorisi)**

PROJE DETAY RAPORU

TAKIM ADI: MEDCOMAI

TAKIM ID: 324300

İçindekiler:

1. Proje Mevcut Durum Değerlendirmesi	1
1.1. U-NET	1
1.2. YOLO	1
1.3. RESNET	1
2. Özgünlük	2
3. Sonuçlar ve İnceleme	3
4. Deney ve eğitim aşamalarında kullanılan veri setleri	7
4.1. Sınıflandırma	8
5. Referans	9



1. Proje Mevcut Durum Değerlendirmesi

Proje sunuş raporunda derin öğrenme metotları üzerine yaptığımız araştırmalar sonucunda seçtiğimiz U-NET, YOLO ve ResNet mimarisinden bahsetmiştik. Proje Sunuş Raporu sonrasında ise bu üç mimari üzerinde araştırmalar yapmaya devam ettik. T.C Sağlık Bakanlığı tarafından sağlanan DICOM formatındaki veri seti bizimle paylaşıldığında ise bu mimariler ile denemeler yaptık. Farklı metotlar üzerinde çalışarak ulaşabileceğimiz en yüksek başarı oranını bulmaya çalıştık.

1.1. U-NET

U-NET mimarisi ile araştırmalarımıza göre tıbbi ve medikal görüntülemelerde daha iyi sonuçlara ulaşacağımızı düşünmüştük. Evrişimli yapıya sahip bu mimaride, elimizde bulunan veri miktarı az olsa bile iyi bir eğitime sahip olmanın mümkün olduğunu destekleyen bazı araştırmalar ile karşılaşmıştık.

Yaptığımız inceleme sonucunda bizlere verilen eğitim setinde patolojilerin maske görüntüsü olmadığı için U-NET modelini sınırlayıcı kutu (bounding box) ile kullanabilmek için araştırmalar yaptık. U-NET modeline maske görüntüsü yerine sınırlayıcı kutu (bounding box) kullanabileceğimiz bir model geliştirdik. Bu modelde yaptığımız deneme sonuçlarında lokalizasyon işleminde yeteri kadar başarıya ulaşamadığımızı gördük. Çalışmalarımızın sonuçlarının yetersiz olması sebebi ile U-NET mimarisini kullanmama kararı aldık. U-NET mimarisinin bounding box yerine maske görüntüleri ile daha verimli çalıştığını anladık.

1.2. YOLO

YOLO mimarisi ile ilgili araştırmalarımızda ise bu mimarinin evrişimsel sinir ağlarını (CNN) kullanarak çıkan bir metot olduğunu görmüştük. Evrişimsel sinir ağlarının (CNN) önemli özelliklerinden biri olan parametre sayısını azaltması ise bu yöntem için dikkatimizi çekmiştir. Parametre sayısının azalması, modeli daha hızlı sonuç vermesine sebep olması ve bunu iyi bir şekilde kullanan YOLO mimarisi kullanabileceğimiz modellerden biri olmuştur. YOLO mimarisi bize hız, yüksek başarı oranı ve mükemmel bir öğrenme kapasitesi sunar.[1] Ayrıca YOLOv4'te bulunan sınırlayıcı kutu (bounding box) regresyonu ve kesiştirilmiş bölgeler ölçütleri (intersection over union, IoU) tabanlı kayıp fonksiyonu sayesinde modelin öğrenme kapasitesi artar. Bu sayede model sınıflandırma ve lokalizasyonda başarılı olacağı tespit edilmiştir.


1.3. RESNET

ResNet mimarisi ile ilgili yaptığımız araştırmalarda normalde çok derin sinir ağlarının eğitilmesi sırasında kaybolan/patlayan gradyanlar nedeniyle oldukça zor olduğunu fark ettik. Fakat ResNet Artık Blok yapısı sayesinde bu sorunu çözerek daha derin katmanlı sinir ağları oluşturmamıza izin veriyor[2]. Bu yüzden ResNet daha derinlere inip daha fazla özellik çıkarabilmesi ile modelin başarısını arttıracaklarını düşündüğümüzden dolayı modelimizde kullanmaya karar verdik.

2. Özgünlük

Sağlık bakanlığı tarafından bize verilen veri setini bellekte işlenecek kadar küçülttüğümüzde tomografi görüntüsünün birçok özelliğinin kaybolduğunu fark ettik. Görüntüleri küçültmeden modele sokup işleyebileceğimiz bir yöntem araştırdık. Araştırmalarımız sonucu “*data generator*” sınıfını kullanmaya karar verdik. Yani, bir veri üretici oluşturursak, eğitim için kullanıldıkları zaman hareket halindeyken görüntüleri okuyabiliriz. Hareket halindeyken görüntüleri okuduğumuz için hafızadan tasarruf ediyoruz. Bu sınıf yapısını resim ön işleme katmanları, tomografi görüntüsünü DICOM çekip array haline getirmesi gibi farklı birçok fonksiyon ekleyerek özelleştirdik.


Kullanmayı düşündüğümüz YOLOv4 ve ResNet Modelleri arasında karar vermekte çok zorlandık. Her iki modelde benzer başarı oranlarına sahipti. Daha önce birkaç makalede YOLO içerisine başka bir modelin omurga olarak kullanıldığını ve daha sonrasında YOLO sınıflandırılması yapıldığını okumuştuk. Testlerimiz ve gözlemlerimiz sonucunda ResNet50 modelinin iyi bir özellik çıkarıcı olduğunu keşfettik. Bunun sonucunda ResNet50 omurgalı bir YOLO modeli yaklaşımına karar verdik. YOLO modelinin özellik çıkaran katmanlar kısmını ResNet50 modeli ile tekrardan model mimarisini oluşturduk. Figür I’de bunu YOLO mimarisi üzerinde görebiliriz.




Figür I: YOLO modeli üzerinde ResNet ekleneceği kısmın gösterimi[3]

Model mimarisini tamamladıktan sonra model üzerindeki parametreleri bize verilen eğitim setini daha iyi tanıyabilmesi için varsayılan parametreleri değiştirdik. Aktivasyon fonksiyonlarında Tanh ve sigmoid fonksiyonları kullanmak yerine daha çok ReLU ve Mish fonksiyonlarını kombinleyerek kullandık.

Bu sayede derin katmanlı modellerde oluşabilme ihtimali yüksek olan gradyan kaybolması probleminin önüne geçmiş olduk. ReLU ile hesaplama karmaşıklığının azalması ve optimizasyon hızının çok hızlı olmasını sağlarken Mish sayesinde ise modelin bilgi depolama kapasitesini ve ayırt etme kapasitesini artırabildik. [4] Bunun sebebi ise Mish tüm pozitif veya tüm negatif türevler yerine bazı noktalarda negatif türevlere ve bazı noktalarında ise pozitif türevlere sahip olmasıdır. [5]



Figür III: Mish aktivasyon fonksiyonunun grafiksel gösterimi



Figür II: Aktivasyon fonksiyonlarının gösterimleri


3. Sonuçlar ve İnceleme

Proje sunuş raporunda kullanmayı düşündüğümüz ResNet modelinin en başarılı 3 yaklaşımı vardır. Bunlar ResNet50, ResNet101 ve ResNet152dir. Bize verilen verilerde sadece etiketlenmiş verileri %80-%20 oranında rastgele olacak şekilde bölünmüştür. Bölünen veriler modeller epok sayısı 50, batch size 64, kayıp fonksiyonu kategori çapraz entropi ve optimizasyon algoritması Rmsprop olacak şekilde test edilmiştir. Testlere ilişkin sonuçlar Tablo 1’de gösterilmiştir.


Model	F1-Skor	Doğruluk (Accuracy)	Duyarlılık (Recall)	Kesinlik (Precision)
ResNet50	0.95	0.96	0.95	0.96
ResNet101	0.94	0.94	0.93	0.95
ResNet152	0.92	0.93	0.92	0.94

Tablo 1: ResNet modellerinin farklı başarı metriklerinde karşılaştırılması

Tablo 1’i incelediğimizde en iyi performans aldığımız modelin ResNet50 olduğu görülmektedir. Modellerden en iyi aldığımız eğitim başarı oranı %96,4 olarak hesaplanmıştır. En iyi başarı oranını aldığımız ResNet50 modeline ait başarı metriklerinin eğitim grafiği Figür IV’te ve modelin test sonuçları ve tablosu ise figür V’de görülmektedir.




Figür V:ResNet50 modelinin başarımlerinin eğitim grafiği



Figür IV:ResNet50 modelinin test sonuçları ve tablosu

ResNet50 üzerinde ResNet'in farklı varyantları, orijinalden tam ön aktivasyona kadar, gradyanların daha önceki katmanlardan herhangi birine kısayol bağlantılarından engellenmeden devam edebileceği şekilde kullanılmıştır.[6]



Figür VI: ResNet'in farklı artık blok varyantları

Bu şekilde kullanmamızın sebebi ise modelin ezberlemeden daha fazla özellik çıkarabilmesini sağlamaktır. Daha sonrasında ResNet50 modelinin sınıflandırıcı katmanlarını kaldırdık ve bu sayede ResNet50 sadece özellik çıkarıcı haline geldi. Bu yaklaşımı daha önce yapıldığını ve ResNetin başarılı bir özellik çıkarıcı olduğunu birçok makale ile desteklenmiştir. Ve ardından YOLOV4 sınıflandırıcı katmanları ile model tamamlanmıştır.

Bu iki modeli bir araya getirmek için C dili ile yazılmış açık kaynaklı sinir ağıları çerçevesi (framework) olan darknet kullanılmıştır. YOLOV4 sınıflandırma katmanı ile ResNet50 modelinin son evrişim katmanı birbirine bağlanmıştır. Kayıp fonksiyonu olarak YOLOv4'dün sınıflandırma, güvenilirlik ve IOU tabanlı kullanıyoruz. Bu sayede hem sınıflandırma hem de lokalizasyon için model daha efektif bir şekilde eğitildi.

$$Loss = L_{CIOU} + L_{conf} + L_{cls}$$

$$L_{conf} = \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{obj} \left[\hat{O}_i \log(O_i) + (1 - \hat{O}_i) \log(1 - O_i) \right] - \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{noobj} \left[\hat{O}_i \log(O_i) + (1 - \hat{O}_i) \log(1 - O_i) \right]$$

$$L_{cls} = - \sum_{i=0}^{S^2} 1_{ij}^{obj} \sum_{o \in class} \left[\hat{P}_i(o) \log(p_i(o)) + (1 - \hat{P}_i(o)) \log(1 - P_i(o)) \right]$$

$$L_{IOU} = \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{obj} (2 - w^{gt} \times h^{gt}) [1 - CIOU(X, Y)]$$


$$CIOU(X, Y) = IOU(X, Y) - \frac{\rho^2(X_{ctr}Y_{ctr})}{m^2} - uv$$

Figür VII: YOLOv4 loss fonksiyonu

Resnet50 omurgalı YOLOv4 modelimizin mimarisi tamamlandıktan sonra model eğitimi için bize verilen etiketli verilerin Excel dosyasında sadece bounding box değeri olan veriler alınıp bir araya getirilmiştir. Daha sonrasında MBB koordinatları YOLO için tekrardan ölçeklendirilmiş ve modele uygun hale getirilmiştir.

Düzenlenen veri %80-%20 olacak şekilde ikiye ayrılmıştır. Ayrıca düzenlenen veri dosyasının içinde '0' etiketli (bulgu yok) tanımı olmadığı için bulgu olmayan verilerden toplam test verisinin 1/7 oranında eklenmiştir.

YOLOv4ün hiper parametre seçimlerini yaparken birçok farklı senaryoda testler yapılmıştır. Bu testlerde en çok önem verdiğimiz parametre learning rate parametresi oldu. 0.1 öğrenme hızıyla, ardından 0.01 ve ardından 0.01, 0.001, 0.0001 ile farklı eğitim testleri yapılmıştır. Bu testlerin ardından bizim modelimiz için en uygun parametrenin 0.001 olduğuna karar verilmiştir. Daha sonrasında diğer parametreleri ise yaptığımız araştırmalar sonucu karar verdik. Hiper parametrelere karar verme aşaması yarışma gününe kadar devam edecektir. Bu süreçte devamlı testler yapılacak ve model devamlı güncellenecektir. Modelimizde hiper parametreleri de belirledikten sonra eğitim aşamasına geçtik. Modelin eğitim sırasında en iyi ağırlıklar ve her 1000 iterasyondaki ağırlığı kaydedilmesi sağlanmıştır. Modele ilişkin loss ve mAP grafikleri figür VIII'de görülmektedir.



Model eğitim sonucunda elde edilen en iyi ağırlıklar ile test yapıldığında aldığımız mAP sonucu %80,73'dür. Yapılan teste ilişkin ayrıntılı değerler ise figür IX'de görülmektedir.

```
detection_count = 6577, unique_truth_count = 5593
class_id = 0, name = bulgu yok, ap = 78.3% (TP = 723, FP = 204)
class_id = 1, name = akut apandisit, ap = 85.1% (TP = 810, FP = 143)
class_id = 2, name = akut kolesistit, ap = 75.7% (TP = 246, FP = 82)
class_id = 3, name = akut pankreatit, ap = 84.4% (TP = 780, FP = 149)
class_id = 4, name = böbrek taşı, ap = 80.2% (TP = 472, FP = 119)
class_id = 5, name = akut divertikülit, ap = 74.8% (TP = 175, FP = 62)
class_id = 6, name = aorta anevrizma, ap = 86.6% (TP = 1045, FP = 171)


for conf_thresh = 0.25, precision = 0.80, recall = 0.82, F1-score = 0.81
for conf_thresh = 0.25, TP = 4251, FP = 930, FN = 542, average IoU = 75 %

IoU threshold = 50 %, used Area-Under-Curve for each unique Recall
mean average precision (mAP@0.50) = 0.807286, or 80.7 %
Total Detection Time: 7468 Seconds
```

Figür IX: YOLOv4 test sonuçları

4. Deney ve eğitim aşamalarında kullanılan veri setleri

Sağlık Bakanlığı tarafından bizlere sağlanan verileri ilk etapta detaylı bir şekilde inceledik. Sağlık bakanlığı tarafından verilen veri seti 1,182 kişinin bilgisayarlı tomografi görüntülerini içerir. Bu görüntülerde toplam 357,405 adet kesit vardır. Bu kesitlerin 38,236 adeti işaretlenmiş 5,348 adeti başlangıç/bitiş kesitlerinden oluşmaktadır. Başlangıç/bitiş kesitleri koordinat bulundurmamaktadır.




Figür X: Veri seti dağılım grafiği

Paylaşılan ilk veride 17 farklı sınıf bulunmaktadır. Bu sınıfların hepsi farklı miktarda bilgisayarlı tomografi kesiti içermektedir. Abdominal aort anevrizma sınıfı 9009 adet, akut pankreatit sınıfı 7121 adet, akut apandisit sınıfı 5991 adet, akut kolesistit sınıfı 5153 adet, böbrek taşı sınıfı 2042 adet, safra kesesi taşı sınıfı 1684 adet, akut divertikülit sınıfı 1152 adet, böbrek-mesane sınıfı 876 adet, abdominal aorta sınıfı 852 adet, abdominal aort diseksiyon sınıfı 814 adet, üreter taşı sınıfı 726 adet, kolon sınıfı 688 adet, pankreas sınıfı 632 adet, safra kesesi sınıfı 594 adet, apandiks sınıfı 468 adet, apendikolit sınıfı 359 adet, kalsifiye divertikül sınıfı 75 adet kesit bulundurmaktadır.

4.1. Sınıflandırma

Paylaşılan bu veri de bu kadar fazla sınıf olması hazırlayacağımız işlemlerde karmaşıklığa sebep olacağından dolayı veri üzerinde bazı değişiklikler de bulunduk. Birkaç sınıfı veriden çıkarıp birkaçını da birleştirdik. Düzenlediğimiz veri setinde işaretlenmiş 36,119 adet kesit vardır. Bu kesitlerin 5,191 adeti başlangıç/bitiş kesitlerinden oluşmaktadır. Bu veri seti 7 farklı sınıf içermektedir. Bulgu yok sınıfı 4111 adet, akut apandisit sınıfı 5991 adet, akut kolesistit sınıfı 5153 adet, akut pankreatit sınıfı 7121 adet, böbrek taşı sınıfı 2768 adet, akut divertikül sınıfı 1152 adet, aorta anevrizma sınıf 9823 adet kesit içerir.



Figür XI: Düzenlenmiş veri seti dağılım grafiği

5. Referans

[1]: A Survey of Deep Learning-based Object Detection

Licheng Jiao, Fan Zhang, Fang Liu, Shuyuan Yang, Lingling Li, Zhixi Feng, Rong Qu

[2]: Deep Residual Learning for Image Recognition

Kaiming He Xiangyu Zhang Shaoqing Ren Jian Sun Microsoft Research

[3]: You Only Look Once', Unified, Real-time Object Detection —
<https://arxiv.org/abs/1506.02640>

[4]: Journal of Physics: Conference Series, Volume 2037, 2021 International Conference on Artificial Intelligence and Information Technology (ICAIIIT 2021) 27-28 March 2021, Beijing, China Citation Min Xu and Chuanhai Jia 2021 J. Phys.: Conf. Ser. 2037 012090

[5]: Activation Functions Compared with Experiments, Sweta Shaw –

<https://wandb.ai/shweta>

[6]: Identity Mappings in Deep Residual Networks-

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun