

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

**(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için Hastalık
Tespiti Kategorisi)**

PROJE DETAY RAPORU

TAKIM ADI: VERİTAS.AI

TAKIM ID: 464248

1. Proje Mevcut Durum Değerlendirmesi	2
2. Özgünlük	3
3. Sonuçlar ve İnceleme	4
3.1. Kısıtlamalar	4
3.1.1. Kaggle'a zip dosyalarının yüklenememesi sorunu	4
3.1.2. Dicom dosyalarının kullanılan framework ile okunamaması sorunu	4
3.1.3. Parser yapısı içerisinde koordinatların float'a çevrilmesi sorunu	4
3.1.4. Transfer learning kullanılırken sınıf sayılarında uyumsuzluk yaşanması sorunu	5
3.1.5. PIL kütüphanesinin inference işlemini engellemesi sorunu	5
3.2. Eğitim ve test sonuçları	5
4. Veri Setleri	7
5. REFERANSLAR	8

1. Proje Mevcut Durum Değerlendirmesi

Modelin eğitimi için kullanılan dicom dosyalarının taşınması, işlenmesi ve üzerinde değişiklik yapılması uzun zaman almaktadır. Bunun nedeni dicom dosyalarının birçok meta data içermesi ve boyutlarının diğer dosyalara kıyasla daha büyük olmasıdır. Bu nedenle dicom formatların “pydicom” kütüphanesi kullanılarak, bir python scripti yazılarak görüntüler png formatına çevrildi. Bu dönüşümlerde görüntülerdeki veri kaybını en aza indirmek için, dicom görüntüler float değer tipindeki Python listelerine çevrilip, “PIL” kütüphanesi yardımıyla bu float listelerinden png görüntüleri üretildi.

Modelin eğitimi için kullanılan IceVision framework birçok yönden avantajlı olmasına rağmen dicom dosyalar ile çalışma konusunda yazılmış dokümantasyonuna ilişkin yavaşlatıcı problemler içermektedir. Bu sebeplerde png formata geçilmesinde etkili olmuştur.

Yapılan işlemlerde GPU üzerine düşen yükün yoğun olması sebebiyle, projenin başında kullanılan bilgisayarın grafik kartının yetersiz olduğu ve ısınma problemleri yaşandığı için eğitim işlemlerinde performans zayıflığı ile vakit kaybına neden olduğu görülmüştür. Bu sebeple daha yüksek performans verebilecek daha güçlü GPU’ya sahip bilgisayara geçilmiştir.

EfficientNet, YoloV5 ve RetinaNet mimarileri kullanılarak farklı modeller eğitilmiştir. EfficientNet için “tf_lite0” YoloV5 için “YOLOv5l” RetinaNet için ise “resnet101_fpn_1x” omurgaları kullanılmıştır. YoloV5 en düşük validation loss değerine sahip olmuştur. EfficientNet kullanılarak eğitilen model en kötü sonucu vermiştir. En iyi sonucu kullanılan örneklem seti bağlamında RetinaNet vermiştir. İleride görüntülerin işlenmesi, veri setleri oluşturulurken kullanılacak örneklem yöntemleri vb. Yöntemler göz önüne alındığında bu sonuçlar değişiklik gösterebilir.

Transfer learning, önceden başka veri setleri üzerinde eğitilmiş modellerin son katmanının ve ağırlıklarının beslenerek yeni bir amaç için çıktı üretilmeye çalışılması işlemidir. Kullandığımız modellerde yapay sinir ağının son nöronu tomografi görüntüleriyle güncellenmiş önceki son nöron öncesindeki ağırlıklar backpropagation işlemi ile güncellemeye tabi tutulmamıştır. Transfer learninge tabi tutulan modeller aynı sınıfa sahip örnekleme yapılarak

seçilmiş farklı veri setleriyle birden fazla kez eğitilmiş. Ağırlıklar kaydedilmiş ve sonraki eğitimlerde tekrar kullanılmıştır.

2. Özgünlük

Geliştirilecek model, yeni bir yaklaşım sunan IceVision frameworküyle yapılacaktır. IceVision frameworkü ilk agnostik görüntü işleme ve obje tespiti aracıdır. Fastai ve PyTorch Lightning gibi yüksek performanslı kolay kullanımlı kütüphanelerin üstüne kurulmuştur. PyTorch ve MMLabs frameworklerinin yüzlerce yüksek performanslı modelinin önceden eğitilmiş, model ağırlıklı haline sahiptir.

Modeli geliştirirken, onlarca modeli aynı anda eğitebilecek, farklı frameworklerin aynı modeli aynı anda eğitmesini sağlayabilecek, benzer modellerin aynı ağırlıklarla nasıl çalıştığını görebilecek, segmentasyon, sınıflandırma ve obje tespiti işlemlerini ortak zamanlı yapabilecek şekilde modeli eğitebilecektir. Geliştirilecek modellerin genelleştirilebilmesi için verilere yönelik yeni bir dönüşüm işlemi uygulanacaktır. Verilerin temizlenmesi otomatize edilecektir.

Kullanılacak yöntemler ve araçlar, klasik görüntü işleme modeli geliştirme süreçlerinin süresini kısaltmayı, daha kısa bir zamanda, daha az fiziksel girdiyle ve daha çok soyutlamayla başarılı sonuçlar elde etmeyi amaçlamaktadır.

3. Sonular ve İnceleme

3.1. Kısıtlamalar

3.1.1. Kaggle’a zip dosyalarının yüklenememesi sorunu

Örnekleme yöntemleriyle, veri seti içindeki oranları korunarak oluşturulan küçük veri setleri zip dosyaları halinde Kaggle ortamına yüklenmeye çalışıldığında Kaggle’dan kaynaklanan bir bugdan dolayı dosyalar yüklenemedi. Çözüm için, Kaggle yardım ortamında başlık açıldı. Eğitim setleri “tar.xz” uzantısına sahip olacak biçimde tekrar sıkıştırılıp, kaggle içerisinden script yazılarak çıkartıldı ve kullanıldı.

3.1.2. Dicom dosyalarının kullanılan framework ile okunamaması sorunu

IceVision frameworkünün dökümantasyonları takip edilerek dicom dosyaları okunmaya çalışıldı. Fakat dicom dosyaları framework metodları tarafından okunamadı. Bu sorunu çözmek için dökümantasyonlar ve GitHub kodları incelendi. Daha sonrasında frameworkün Discord forumuna üye olunarak frameworkün geliştiricilerinden yardım istendi. Karşılaşılan sorunun kaynağının frameworkün yanlış bir versiyonun kullanılması olduğu görüldü. Doğru versiyon kullanılıp dicom dosyaları okunduğunda görüntülerin yüksek gürültüye sahip olarak okunduğu görüldü. Bu sorunla ilgili PyDicom kütüphanesi kullanılmaya çalışıldı ama başarılı bir sonuç elde edilemedi. Görüntüler png dosyalarına çevrilip modeller böyle eğitildi. Sadece excel dosyasında olgu ve kesit numarası olan görüntüler kalacak şekilde büyük veri setinden yeni bir veri seti oluşturuldu.

3.1.3. Parser yapısı içerisinde koordinatların float'a çevrilmesi sorunu

Paylaşılan veri setinde kesitlerdeki hastalıklar koordinatlar adı verilen sütun altına yazılmıştır. Bu koordinat verileri temizlenmesi gereken string ifadelerdir. Parser, veri setine göre öznel olarak tasarlanabilen eğitim ve test setlerine gönderilecek fotoğrafları nasıl yapılandıracağımızı sağlayan bir sınıftır. Parser içerisinde bounding boxları oluştururken xmin, ymin, xmax, ymax sırasına göre string koordinat değerlerini parçalayacak, floata çevirecek ve atama yapacak bir script yazılmıştır.

3.1.4. Transfer learning kullanılırken sınıf sayılarında uyumsuzluk yaşanması sorunu


İlk başlarda örnekleme yapılarak oluşturulan ufak veri setlerinin içerdiği sınıf etiketi sayıları birbirinden farklıydı. Öncesinde başka bir örneklem ile eğitilmiş model, yeni bir veri seti ile tekrar eğitileceği zaman sınıf sayılarındaki uyumsuzluk nedeniyle hata alınmaktaydı. Model checkpoint üzerinden oluşturulduktan sonra, modifiye edilip sınıf haritasına yeni veri setinin parserinin sınıf haritası atandı.

3.1.5. PIL kütüphanesinin inference işlemini engellemesi sorunu

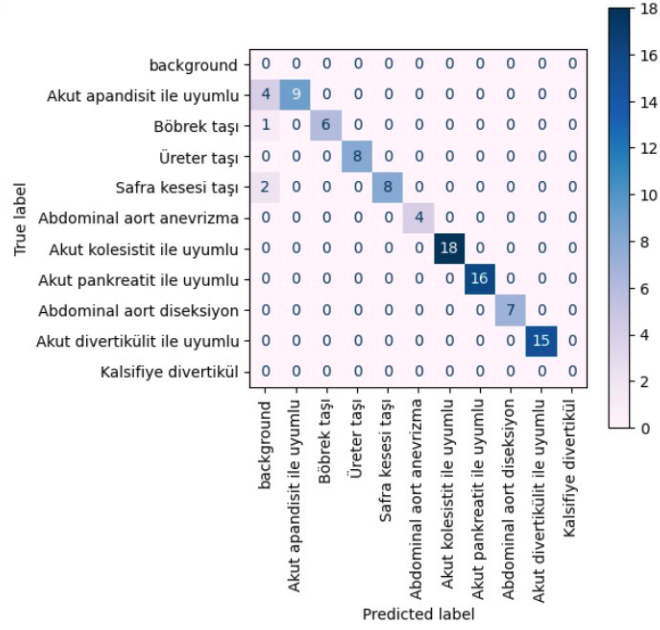
Çalışmamızda inference denen bir kısım bulunmaktadır. Inference, eğitilen ve test edilen modele test ve eğitim verisi dışında dışarıdan görüntüler verilmesi ve görüntüler üzerinde tahmin yapılması üzerine kurulu bir süreçtir. Dicom dosyalarından png dosyalarına çevirilen görüntüler 3 boyutlu şekilde elde edilmiştir. Fakat PIL kütüphanesi bu dosyaları açarken üçüncü boyutu silmektedir. Bu nedenle boyutlarda uyumsuzluk yaşanmıştır. Bu sorun Keras'ın görüntü yükleme metodları kullanılarak aşılmıştır.

3.2. Eğitim ve test sonuçları

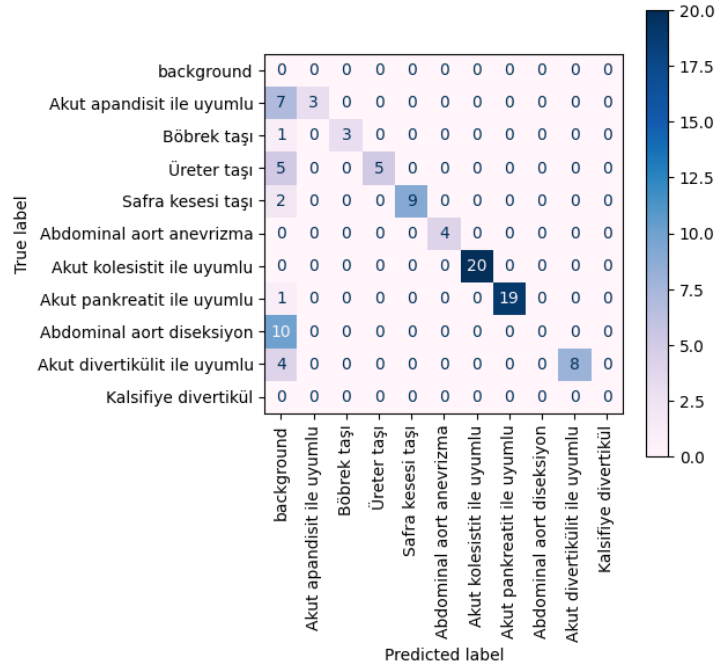
Model, test veri seti üzerinde test edilmiştir ve bu veri seti üzerinde yapılan tahminlerden oluşturulan dizi kullanılarak bir confusion matrix oluşturulmuştur. Modellerin karşılaştırılmasında validation loss, training loss, accuracy, mAP gibi metrikler esas alınmıştır.



Yolov5 ile yapılan eğitim için Confusion Matrix




RetinaNet ile yapılan eğitim için Confusion Matrix



EfficientNet ile yapılan eğitim için Confusion Matrix

```
4]: show_preds(preds = preds[70:72], figsize= (12,8))
```



Test veri seti üzerinde tekli ve çoklu etiket tahminleri



Inference (dışarıdan verilen fotoğraf) üzerinde tahmin

Model başarı metriklerinin karşılaştırılması

Model	Training Loss	Validation Loss	Accuracy
YoloV5	0.096547	0.096661	77.2
RetinaNet	0.269350	0.170370	92.7
EfficientNet	0.443041	0.322009	71.4

4. Veri Setleri

Eğitimde modeller sadece Teknofest'in sağladığı veri seti ile eğitilmiştir. Bunun dışında bir veri seti kullanılmamıştır. Veri setinin boyutu çok büyük olduğu, yeterli donanımın elimizde bulunmamasından dolayı Kaggle, Colab gibi ortamlar kullanılmak zorunda kalınmıştır. Bu platformlarda, yüksek batch sayısı ile çalışılması kullanıcılara sağlanan RAM'in yetersiz kalması sebebiyle modeller eğitim sırasında hata fırlatmaktadır. Platformların önerisi üzerine, batch ve worker sayıları 2'ye çekilmiştir. Bu da veri setlerinin ufak boyutlar halinde platformlara yüklenmesi ve eğitilen modelin kaydedilip daha sonrasında tekrar eğitilmesine karar verilmesine neden olmuştur. Sağlanan veri seti, png'ye dönüştürüldükten sonra, Kaggle gibi platformlarda hızlıca kullanılabilmesi için dengeli bir şekilde her sınıftan örneklerin alınmasını sağlayacak bir Python scripti yazılarak ufak örneklem kümeleri oluşturulmuştur.

5. REFERANSLAR

- Baumgartner, M., Jäger, P. F., Isensee, F., Maier-Hein, K. H. (2021). NnDetection: A self-configuring method for medical object detection. Medical Image Computing and Computer Assisted Intervention – MICCAI 2021, 530–539. https://doi.org/10.1007/978-3-030-87240-3_51
- Jha, D., Ali, S., Tomar, N., Johansen, H., Johansen, D., Rittscher, J., Riegler, M., Halvorsen, P. (2021). Real-time polyp detection, localization and segmentation in colonoscopy using Deep Learning. IEEE Access, 9, 40496–40510. <https://doi.org/10.1109/access.2021.3063716>
- Lemay A., 2019. "Kidney Recognition in CT Using YOLOv3
- Li, Yongling & Qin, Yong & Xie, Zhengyu & Cao, Zhiwei & Jia, Limin & Yu, Zujun & Zheng, Jian & Zhang, Ehui. (2020). Efficient SSD: A Real-Time Intrusion Object Detection Algorithm for Railway Surveillance. 391-395. 10.1109/SDPC49476.2020.9353137.
- Morera, Angel & Sanchez, Angel & Moreno, A.B. & Sappa, Angel & Vélez, Jose. (2020). SSD vs. YOLO for Detection of Outdoor Urban Advertising Panels under Multiple Variabilities. Sensors. 20. 4587. 10.3390/s20164587.
- Sheoran M., Dani M., Sharma M., Vig L., 2022. “AN EFFICIENT ANCHOR-FREE UNIVERSAL LESION DETECTION IN CT-SCANS”. IEEE International Symposium on Biomedical Imaging. New Delhi, Hindistan
- Tan, Lu & Huangfu, Tianran & Wu, Liyao & Chen, Wenying. (2021). Comparison of RetinaNet, SSD, and YOLO v3 for real-time pill identification. BMC Medical Informatics and Decision Making. 21. 10.1186/s12911-021-01691-8.
- Yan, K., Cai, J., Zheng, Y., Harrison, A. P., Jin, D., Tang, Y., Tang, Y., Huang, L., Xiao, J. Lu, L. (2021). Learning from multiple datasets with heterogeneous and partial labels for universal lesion detection in CT. IEEE Transactions on Medical Imaging, 40(10), 2759–2770. <https://doi.org/10.1109/tmi.2020.3047598>
- URL 1. <https://docs.fast.ai/>
- URL 2. <https://github.com/airetic>
- URL 3. <https://github.com/obss/sahi>
- URL 4. <https://pyimagesearch.com/2022/01/03/torch-hub-series-3-yolov5-and-ssd-models-on-object-detection/>