

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

YAPAY ZEKA YARIŞMALARI

(Biyoinformatik Alanında Yapay Zekâ Destekli Analiz
Metotları Geliştirilmesi Kategorisi)

PROJE DETAY RAPORU

Hücre Morfolojisi İncelenerek Genotipik Bozuklukların
Tayiniyle Kanserin Saptanması

TAKIM ADI

BIOWARE

TAKIM ID

468234

İçindekiler

[1. Uygulama Tanımı](#)

[2. Proje Mevcut Durum Değerlendirmesi](#)

[3. Algoritmalar ve Yapay Zeka Modeli](#)

[3.1 Sinir Ağı Mimarileri ve Hiper Parametreler](#)

[4. Özgünlük](#)

[5. Sonuçlar ve İnceleme](#)

[6. Referanslar](#)




1. Uygulama Tanımı

Kanser; vücudun herhangi bir organında ya da dokusunda kontrolsüzce büyümeye başlayan, kendi sınırlarından çevredeki dokulara doğru ilerleyen ve en sonunda vücuda yayılan geniş bir hastalık grubudur. Neoplazm ve malign tümörler kanserin diğer yaygın adıdır. Dünya Sağlık Örgütü (DSÖ/World Health Organization-WHO)'nın verilerine göre tüm dünyada ölümlerin ikinci temel nedeni olarak kanser yer almaktadır. Ekonominin temel taşlarından biri olan sağlık hizmetlerinde dijital dönüşüm ile kısa sürede önemli bir yol kat etmiştir. Dijital dönüşümle birlikte sağlık konusunda potansiyele sahip olan yapay zeka kavramı hayatımıza girmiştir. Yapay zeka sağlık alanında erken teşhis, tanı, tedavi, araştırma, sağlığı koruyup sürdürme alanlarında karşımıza çıkmaktadır. Özellikle yapay zekanın kanserin türünün kesin olarak belirlenmesi ve gerekli tedavinin planlanabilmesi için kanserli hücre ve dokuları mikroskop altında inceleyen patoloji bulgularının yorumlanmasında kullanılmasıyla birlikte patolojik sonuçlar hızlı, yüksek doğrulukta ve inceleyen kişiye bağlı olmadan elde edilmektedir. Literatürde tümör dokusu için hazırlanan patoloji slaytlarının yapay zeka ile tespiti, kanser tanısı ve kanserin karakterizasyonu ile ilgili pek çok çalışma yapıldığı görülmüştür. Bu durum da bizlere patoloji alanında yapay zeka destekli uygulamaların gerekliliği ve kullanışlı olacağını göstermektedir.¹

Kolon adenomları kanser özelliği taşımayan iyi huylu tümör tipleridir. Adenomlar eğer tedavi edilmez ve tedaviden sonra düzenli takibi yapılmazsa adenokarsinomlara dönüşebilmektedir. Ayrıca adenomların sahip olduğu displazi (dokunun biçimsel bozukluğu) derecesi adenomun davranışını ve adenokarsinoma dönüşümü hakkında genel bir ipucu vermektedir. Yüksek displazi derecesi adenomun daha agresif ve kanserleşme riski olduğunu göstermektedir. Ayrıca yüksek displazi ve mikroinvazyonun başladığı İntramuskular carcinoma olarak adlandırılan ve tümörlerin kasa doğru invazyon yaptığı evreyi tespit etmek de kolon adenokarsinomlarının erken teşhisi ve başarılı tedavisi için önemlidir.²

Kanserde Evre 0 olarak adlandırılan periyotta, anormal hücrelerin olduğu ancak hücrelerin çevreye yayılmadığı ve Karsinom İn Situ (Carcinoma İn Situ- CIS) olarak adlandırılan bir süreç bulunmaktadır.³ Bu evrenin tespiti ise kanserde erken teşhis sağlayan ve tedaviye erken başlanmasına yardımcı olan bir etkidir. Ancak bu evrenin kolay tespit edilemeyişi kanserde erken teşhisin sağlanamadığı durumlardan biridir. Bu evrede invazyonun tespiti ile doğru kanser tanı konmaktadır. Ancak patolojik slaytlar üzerinde Evre 0'ın tespit edilmesi inceleyen patoloğun vaktini almakla beraber, doğru tanı inceleme yapan patoloğun uzmanlığı ve bilgisine göre de değişmektedir.

Bu projede; patolojik slaytlar üzerinde yapay zeka destekli uygulama sayesinde CIS tespiti hedeflenmektedir. Birçok kanser tipinde CIS evresi bulunduğu için uygulamamız farklı kanser türlerinin de eklenebileceği bir imkan sağlamaktadır. CIS evresinin yapay zeka ile tespiti sayesinde de kanserde erken teşhisin yapılmasını sağlayacaktır. Bu sayede de kanserde tedavinin başlanması ve tedavi başarısı ile sağkalım oranlarındaki artış hedeflenmektedir.



Şekil 1: Projenin Genel Şeması

2. Proje Mevcut Durum Değerlendirmesi

Proje Sunuş Raporunda çözüm bölümünde belirtilen metotlar daha fazla geliştirilerek yeni bir algoritma şeması tasarlanmıştır. Hasta biyopsi preparatları uygun filtrelemeler yapılarak seçilmiştir. Daha sonrasında örnekler taranarak sanal ortama aktarılmış ve görseller pre-processing aşamasında öncelikle Whole Slide Imaging, sonra arka plan temizleme ve sonrasında görüntülerin bölünmesi yapılarak yazılan algoritmada eğitilmiştir.

Projenin ön tasarım raporu süresince yapılan zaman planlamasında değişiklik olmamıştır, bu nedenle zaman analizinde herhangi bir değişiklik yapılmamıştır. Elimizde fazla hasta verisi olmasına rağmen donanımsal yetersizlik sebebiyle proje detay raporuna kadar 4 hasta verisiyle çalışılmıştır. Training sonucunda elde edilen loss değeri Şekil3'te gösterilmiştir. Proje detay raporundan sonra daha fazla hasta verisinde daha uzun süreli eğitim yapılarak yüksek başarılı sonuçlar elde etmeyi planlıyoruz.

3. Algoritmalar ve Yapay Zeka Modeli


Çalışmada kullanılan kod Python (3.6) yazılım dilinde Pytorch kütüphanesi kullanılarak visual studio code uygulamasında <https://github.com/onermustafaumit/SRTPMs> adresli github başlığından yararlanılarak implemente edilmiştir.

Kullanılan donanımın özellikleri aşağıdaki gibidir:

- İşletim sistemi: Windows 10 , 64-bit operating system
- RAM: 16GB
- İşlemci: Intel(R) Core(TM) i7-9750H CPU @ 2.60GHz 2.60 GHz
- Grafik işlemci: NVIDIA GeForce GTX 1660 Ti

Çalışmada histopatolojik görüntülerin analizi 2 derin öğrenme modeli kullanarak gerçekleştirilmiştir.

Tüm slayt görüntüleri çok büyük boyutludur, genelde 100.000 x 100.000 piksel olmaktadır. Veri ön işleme kapsamında yüksek boyutlu görüntülerin büyüklüğünü azaltmak için arka plan silme işlemi uygulanmıştır. Derin öğrenme algoritmaları girdi olarak hep aynı boyutta veri aldığı için eldeki görüntü bir ızgaradan geçirilerek 512 x 512 piksel boyutunda kareler halinde bölünmüştür. Mitotik figürler, pseudostratifikasyon ve çekirdek konumlanması gibi displaziye ait karakteristik özelliklerin daha belirgin olması için 40x yakınlaştırmada alınan görüntüler kullanılmıştır ve kesme işlemi 40x yakınlaştırmada yapılmıştır. Elde edilen görüntülere ayna görüntüsü alma, döndürme, rastgele kırpma şeklinde veri augmentasyonu methodları uygulanıp parça boyutu 299 pixele düşürülmüştür. Böylece preparatın farklı bölgelerinden rastgele alınmış olan 200 parça, preparatı temsil eden torbayı oluşturmuştur. Her preparattan torbalar alınarak eğitim setimiz oluşturulmuştur.




Şekil 2: Görüntülerin Pre-processing Aşamaları (WSI: Whole Slide Imaging)

İlk aşamada hematoksin&eosin lekeli dijital histopatoloji slaytlarından displazi seviyesini tahmin eden derin öğrenme tabanlı çoklu örnek öğrenme (Multiple Instance Learning) modeli kullanılmıştır.

Displazi tahminini bir çoklu örnek öğrenme (Multiple Instance Learning, MIL) görevi olarak formüle edilmiş olup bir numune; numunenin slaytlarından kırpılmış rastgele parçalardan oluşan bir torba olarak temsil edilmiş ve numunenin displazi seviyesi torbanın etiketi olarak kullanılmıştır. Model eğitim seti üzerinde eğitilmiştir (kat0, kat1 ve kat2); doğrulama setine göre en iyi model seçilmiş (kat3) ve son olarak bekleme test setinin görünmeyen hastaları üzerinde test edilmiştir (kat4).

3.1 Sinir Ağı Mimarileri ve Hiper Parametreler

Öznitelik çıkarma modülü olarak bir ResNet188 modelini ve torba düzeyinde temsil dönüştürme modülü olarak üç katmanlı çok katmanlı algılayıcıyı kullanılmıştır. Torbanın içindeki her bir örnek için 128 özellik çıkarılmıştır. MIL modellerinde kullanılan hiper parametrelerin mimarisi ve listesi aşağıda verilmiştir.



Şekil 3: Genel Algoritma Şeması⁴

Architecture	input - $299 \times 299 \times 3$ ResNet18 (128 nodes in the last fc layer) 'distribution' pooling Dropout(0.5) fc-384 + ReLU Dropout(0.5) fc-192 + ReLU Dropout(0.5) fc-1 (regression)
patch size	512×512
random crop size	299×299
# instances per bag (N)	200
# features (J)	128
# bins in 'distribution' filters	21
σ in Gaussian kernel	0.05
Optimizer	ADAM
Learning rate	$1e - 4$
$L2$ regularization weight decay	0.0005
batch size	1

Tablo 1: MIL modellerinde kullanılan sinir ağı mimarisi ve hiper parametrelerin listesi.

4. Özgünlük

Patoloji slaytlarının incelenmesi pek çok yöntem bulunmakla beraber genel olarak doku boyası ve İmmünohistokimyasal boyamalar kullanılmaktadır. Tanıların konulamadığı ya da şüpheli olduğu durumlarda da genetik testler uygulanmaktadır. Özellikle ara evrelerde tanı daha zor konduğu için spesifik bir tedaviye başlanma süresi de gecikmektedir. Projemiz

sayesinde hem bu sürenin kısaltılarak kanserin Evre 0'da tespiti sağlanacak olup kesin tanı için uygulanması gereken IHC boyamaları ve genetik testlerin gerekliliği azalacaktır.

Literatürde, farklı çalışma gruplarının yapmış olduğu dijital patoloji yazılımları olmakla beraber rutinde tanıda yardımcı olarak kullanılan dijital patoloji cihazı çok fazla bulunmamaktadır. Olan cihazlar ise daha çok patoloğların tanı süresini kısaltmaya yönelik olan boyanan hücre çekirdeği ya da protein sayımı ve oran belirleme üzerinedir. Türkiye'de yapılan çalışmalar incelendiğinde ise lösemi üzerine geliştirilen ve kanserli hücreleri tanıyan yapay zeka çalışması bulunmaktadır⁵; bunun dışında ek çalışmaya rastlanmamıştır. Dünya çapında yapılan çalışmalar ise yapay zeka ile histopatolojik örneklerle tanı kanser tanısı koyan⁶ ya da kanserin karakteristik özellikleri (mutasyon, prognoz, ilaç direnci, vb.)⁷ ile ilgili fikir veren yazılımlar bulunmaktadır. CIS tespiti sağlayan çalışmalar diğer gruplara kıyasla çok azdır. Yapay zeka ile CIS tanısının çoğu meme^{8,9} kanseri üzerine yapılmış olup duktal karsinom in situ (DCIS) tanısını sağlamaktadır.

Bu çalışmada literatürde yapılan bu çalışmalardan farklı olarak CIS tanısı sağlanacak olup kolon dokuları üzerine çalışma yapılacaktır. Kolon poliplerinden biri olan adenomlar popülasyonda sıklıkla görülmekle birlikte displazi oranları yükseldikçe adenokarsinomlara dönüşme ihtimalleri de artan bir patolojik durumdur. Bu çalışmada da kolon adenomları seçilerek literatürdeki çalışmalardan farklı bir kanser türünün erken evre tespiti sağlanmıştır. Ayrıca rutinde kullanılan bir yöntem olmayışı da bir diğer avantajdır. Yapılacak proje sayesinde ise rutinde kullanılan belirteç boyamaları kullanılmadan sadece histopatolojik slayt üzerinden kanser tanısı erken evrelerde ve uygun fiyatlı olarak sağlanacaktır.

5. Sonuçlar ve İnceleme


Çalışmada kullanılan veri Kanser Genom Atlası ve üniversite hastanesinden retrospektif olarak etik kurul izni ile temin edilecektir. Kanser Genom Atlası (<http://cancergenome.nih.gov/>) (TCGA) Amerika Ulusal Kanser Enstitüsünün (NCI) yürüttüğü, kanser histopatoloji görüntülerinin ve kanserin genetik bilgilerinin depolandığı bir veri tabanıdır. Formalinle fikse edilerek parafine gömülmüş olarak saklanan Hematoksin Eozin boyaması yapılmış kanserli doku preparatları tüm slayt görüntüsü şeklinde indirilecektir. Tüm slayt görüntüsü özel preparat tarama cihazlarıyla elde edilmekte ve dijital ortama aktarılmaktadır.

Üniversite hastanesinden alınan kanserli slaytlar preparat tarama cihazları ile dijital hale getirilecektir. Bunun için hastane veri tabanında yer alan hasta kayıtları incelenerek kolon adenomlarından yüksek ve düşük dereceli displaziler olmak üzere hasta örnekleri seçilmiş olup arşivden bu preparatlar çıkarılmıştır. Çıkarılan preparatlar renk ve kesit kalitelerine göre tekrar seçildikten sonra tarama cihazında taranarak sanal ortama aktarılmıştır. Preparatların taraması İTÜ Arı Teknopark'ta bulunan ARGENİT firmasında EasyScan cihazıyla yapılmıştır.

Kullanılacak olan verilerin TCGA görüntüsü olanları erişime açık verilerdir. Hastaneden alınacak olan hasta biyopsi görüntüleri için de etik kurul başvurusu yapılmış olup onay süreci beklenmektedir.

Kolon adenomları bir polip türü olup displazi oranlarına göre kolon adenokarsinomlarına dönüşen bir patolojik durumdur. Çalışmamızda kolon adenomları üzerinde yer alan displazi dereceleri ve mikroinvazyonların yapay zeka ile tanısı planlanarak kolon adenokarsinomlarında erken evre teşhisi hedeflenmiştir. TCGA'den alınan veriler ile de dış validasyon (external validation) yapılması hedeflenmektedir. 50 adet yüksek dereceli, 15 adet düşük dereceli hasta biyopsi preparatı taranarak sanal ortama aktarılmış ve bölgelerindeki displaziler belirlenmiştir. Ancak elimizdeki donanımsal kaynakların (computational resources) yetersizliği sebebiyle yapay zekanın eğitimi noktasında sorun yaşanmış olup bu sorun erken evrede çözülemediği için hazırlanan yapay zeka 2 adet düşük dereceli ve 2 adet yüksek dereceli olmak üzere toplam 4 hasta verisiyle eğitilmiştir. İleriki dönemlerde donanım imkanları geliştirilerek daha fazla hasta verisiyle eğitim yapılacak olup TCGA verileri de eklenerek external validation yapılacaktır.

Ayrıca çalışmanın bu bölümünde mikroinvazyonlar çalışılmamış olup sadece displazinin derecesi yapay zekayla tespit edilmektedir. Bundan sonraki aşamalarda daha fazla hasta örneği taranarak mikroinvazyonlar belirlenerek geliştirilen yapay zeka modeline displaziye ek olarak mikroinvazyon varlığının tespiti de eklenecektir.



Şekil 4: Eğitilen Algoritmanın Eğitim Sonucu

6. Referanslar

- [1] Cancer, Erişim adresi: https://www.who.int/health-topics/cancer#tab=tab_1, Erişim tarihi: 12.04.2022
- [2] Konishi F, Morson BC. Pathology of colorectal adenomas: a colonoscopic survey. J Clin Pathol. 1982 Aug;35(8):830-41. doi: 10.1136/jcp.35.8.830. PMID: 7107955; PMCID: PMC497798.

[3] Eriřim adresi:

<https://www.cancer.gov/publications/dictionaries/cancer-terms/def/carcinoma-in-situ> Eriřim tarihi: 12.04.2022

[4] Oner, M. U., Chen, J., Revkov, E., James, A., Heng, S. Y., Kaya, A. N., ... & Lee, H. K.

(2022). Obtaining spatially resolved tumor purity maps using deep multiple instance learning in a pan-cancer study. *Patterns*, 3(2), 100399.

[5] Varol, A. B. & İřeri, İ. (2019). Lenf Kanserine İliřkin Patoloji Görüntülerinin Makine Öğrenimi Yöntemleri ile Sınıflandırılması. *Avrupa Bilim ve Teknoloji Dergisi*, Special Issue 2019, 404-410 . DOI: 10.31590/ejosat.638372

[6] Litjens, G., Sánchez, C., Timofeeva, N. et al. Deep learning as a tool for increased accuracy and efficiency of histopathological diagnosis. *Sci Rep* 6, 26286 (2016). <https://doi.org/10.1038/srep26286>

[7] Ehle, A., Rindtorff, N.T., Brinker, T.J. et al. Deep learning in cancer pathology: a new generation of clinical biomarkers. *Br J Cancer* 124, 686–696 (2021). <https://doi.org/10.1038/s41416-020-01122-x>

[8] Wetstein, S.C., Stathonikos, N., Pluim, J.P.W. et al. Deep learning-based grading of ductal carcinoma in situ in breast histopathology images. *Lab Invest* 101, 525–533 (2021). <https://doi.org/10.1038/s41374-021-00540-6>

[9] A deep learning model for breast ductal carcinoma in situ classification in whole slide images, Fahdi Kanavati, Shin Ichihara, Masayuki Tsuneki, medRxiv 2022.01.14.22269329; doi: <https://doi.org/10.1101/2022.01.14.22269329>

