

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için

Hastalık Tespiti Kategorisi)

PROJE DETAY RAPORU

TAKIM ADI: Sirius


TAKIM ID: 465989

İçindekiler

1. Proje Mevcut Durum Değerlendirmesi (20 puan)
2. Özgünlük (30 puan)
3. Sonuçlar ve İnceleme (30 puan)
4. Deney ve Eğitim Aşamalarında Kullanılan Veri Setleri (15 puan)
5. Referanslar (5 puan)

1-Proje Mevcut Durum Değerlendirmesi (20 puan)

Proje Sunuş Raporundan bu yana Sirius takım üyeleri değişmemiştir. Sirius takımı 2 Lise Öğrencisi ve 1 Adet Danışmandan oluşmaktadır. Proje Sunuş Raporunda bahsedilen YOLOv5 algoritmasında herhangi bir değişiklik yapılmamıştır. Özgünlük kısmında ise proje sunuş raporunda bahsedilen sistemlere ek olarak hiper parametreler ve yeni veri seti artırma teknikleri kullanılmıştır. Donanım kısmında ise sunuş raporunda bahsedilen donanımlardan daha güçlü ve hızlı işleme kapasitesine sahip donanımlar elde edilmiş ve model eğitimi bu donanımlar üzerinden sağlanmıştır. Proje Sunuş Raporundan şu ana kadar yapılan işlemlerin işleyiş akışı Şekil 1’de verilmiştir. Yapılan işlemlerden ilk olarak Sağlık Bakanlığı tarafından verilerin eldesi bulunmaktadır. Verileri elde etmek için ilk olarak Kurumsal Gizlilik Tahaattütname belgeleri imzalanmıştır. Veriler elde edildikten sonra eğitilecek algoritma bir YOLO algoritması olduğu için veri seti YOLO formatına getirilmiştir ve veri seti YOLOv5 modeline girdi olarak girmeye hazır hale getirilmiştir. Model eğitiminde hiperparametreler ve çeşitli artırma teknikleri kullanılarak yüksek doğruluk oranlı bir model eğitilmiştir. Sonuç olarak elde edilen modelin başarılı sayılabilecek bir doğruluk oranı elde ettiği belirlenmiştir. Model doğruluk oranını arttırımı için çalışmalar devam etmektedir.




Şekil 1 İşleyiş Şeması

2-) Özgünlük (30 puan)


2.1 YOLOv5 Algoritması ve YOLO Formatı

Bu çalışmada Abdomen(Karın) bölgesindeki hastalıkların MBB (Minimum Bounding Box) değerlerini belirlemek ve için kullanılan nesne tespit (object dedection) algoritması YOLOv5'tir. YOLOv5 algoritmasının tercih edilmesinin sebebi güncel bir algoritma olmasıdır. Ayrıca YOLOv5, Faster R-CNN gibi benzer object dedection algortimalarından daha yüksek çıkarım (inference) hızı ve doğruluk oranı vermesi sebebiyle tercih edilmiştir[1]. Ayrıca YOLOv5 algoritmasının tercih edilmesinin bir diğer nedeni olarak da değişik konfigürasyonlu yani ön eğitilmiş (pretrained) modellere sahip olmasıdır[Şekil 2]. Böylelikle değişik konfigürasyonlu yapay zeka modelleri eğitilmiş ve en yüksek doğruluk oranına sahip olan model belirlenmiştir.



Şekil 2 YOLOv5 Alt Modeller

Şekil 3'te YOLOv5 algoritmasını çalışma prensipleri verilmiş; Şekil 4'te ise YOLOv5 modelinin doğruluğunu belirlemek için kullanılan loss değerini hesaplamada kullanılan formüller verilmiştir.




Şekil 3 YOLOv5 Çalışma Prensip([6])

$$Loss = \lambda_1 L_{cls} + \lambda_2 L_{obj} + \lambda_3 L_{loc}$$


$$L_{obj} = 4.0 \cdot L_{obj}^{small} + 1.0 \cdot L_{obj}^{medium} + 0.4 \cdot L_{obj}^{large}$$

Şekil 4 YOLOv5 Modelinin Doğruluğunu Belirleme Formülleri([6])

YOLOv5 nesne tespit (object dedection) modelini eğitebilmek için verilerin YOLO formatında olması gerekmektedir. Şekil 5’te YOLO formatına ait görsel bulunmaktadır. Bu formata göre veriler train,test ve validation olmak üzere 3 klasörde bulunmaktadır. Image Klasörlerinde resim verileri bulunmakta ve Labels klasörlerinde her bir resim verisine o ait bir text(.txt uzantılı) label dosyası bulunmaktadır. Text dosyasının içindeki değerler sırasıyla: o resimde bulunan bulgunun ait olduğu sınıf ve 4 adet **normalleştirilmiş koordinat değerleridir**. Şekil 4’te örnek bir text dosyasına ait yapı bulunmaktadır. Bu örnekte ilk başta bulunan “0” değeri bu resmin 0.sınıfa ait olduğunu belirtmekte, diğer değerler de (0.48, 0.44, 0.28, 0.32) bu resimde bulunan bulgunun sahip olduğu YOLO formatına göre normalleştirilmiş koordinat değerlerini ifade etmektedir.



Şekil 3 YOLO Veri Seti Formatı



Şekil 4 Text Dosyası Örneği

Sağlık Bakanlığı tarafından verilen veriler ile YOLOv5 nesne tespit (object dedection) algoritmasını eğitmek için ilk olarak verilerin yukarıda bahsedilen YOLO formatına dönüştürülmesi gerekmektedir. Bunun için de ilk olarak bulgu içeren görsellere ait labellar yani text (.txt, uzantılı) dosyalar oluşturulmuştur. Bulgu içeren görsellere ait labelları oluşturmak için ilk olarak Sağlık Bakanlığı tarafından verilen verilerin içinde bulunan excel dosyasındaki bulgulara ait koordinat değerleri YOLO formatına dönüştürülerek normalleştirilmiştir. Normalleştirme işlemine ait kod parçası Şekil 5’te verilmiştir. Sağlık Bakanlığı tarafından verilen verilerin içinde bulunan excel dosyası üzerinden Normalleştirme işlemi gerçekleştirilirken OPENCV, Pandas ve Numpy kütüphanelerinden yararlanılmıştır.

```
def xml_to_yolo_bbox(bbox, w, h):
    x_center = ((bbox[2] + bbox[0]) / 2) / w
    y_center = ((bbox[3] + bbox[1]) / 2) / h
    width = (bbox[2] - bbox[0]) / w
    height = (bbox[3] - bbox[1]) / h
    return [x_center, y_center, width, height]
```

Şekil 5 Normalleştirme İşlemine Ait Kod

Bulgulara ait koordinatlar değerleri normalleştirildikten sonra her bir bulgu için ayrı ayrı text dosyaları yani labellar elde edilmiştir. Labellar elde edilirken Pandas, Numpy ve OpenCV kütüphaneleri kullanılmıştır. Şekil 6 ve 7’de labellar elde edilirken kullanılan kodlardan önemli parçalar verilmiştir.

```
for x in range(egitim_dosyası.shape[0]):
    liste = [MinX[x],MaxY[x],MaxX[x],MinY[x]]
    liste[0] = int(liste[0])
    liste[1] = int(liste[1])
    liste[2] = int(liste[2])
    liste[3] = int(liste[3])
    a = int(MaxX[x]) - int(MinX[x])
    b = int(MaxY[x]) - int(MinY[x])
    yol = "Kapsul3/" + path
    img = cv2.imread(yol[x])
    dh, dw, _ = img.shape
    sonuc = xml_to_yolo_bbox(liste, dw, dh)
    sonuclar.append(sonuc)
```

Şekil 6 Tüm Koordinatların Normalleştirilmesi

```
for a in range(egitim_dosyası.shape[0]):
    text = "{} {} {} {} {}".format(sinif[a], sonuclar[a][0],
    sonuclar[a][1],sonuclar[a][2],sonuclar[a][3])
    f= open("{}".format(name[a]),"w+")
    f.write(text)
    f.close()
```

Şekil 7 Text Dosyalarının Oluşturulması


Bulguların tespit edildiği Bilgisayarlı Tomografilerine ait labellar elde edilince veri seti %70 Eğitim (Train) %20 Test ve % 10 Validation olmak üzere 3 parçaya ayrılmıştır. Böylelikle veri seti YOLO formatına getirilerek eğitime hazır hale gelmiştir.

2.2 Veri Seti Arttırma Teknikleri

Sağlık Bakanlığı tarafından veriler çeşitli Python kütüphaneler ile analiz edilmiştir. Yapılan analizler sonucunda veri setindeki bulguların homojen bir şekilde olmadığı belirlenmiştir. Bunun sonucunda ise veri setinin dengeli hale getirmek için çeşitli augmentation teknikleri uygulanmıştır. Bu augmentation teknikleri sırasıyla şöyledir: Mosaic, Copy Paste, MixUp, Augment HSV ve son olarak Rastgele Yatay Çevirmedir.

2.2.1-) Mosaic

Mosaic augmentation yönteminde veri setinde bulunan fotoğrafların bir resim üzerinde birleştirilerek çoğaltılması ile veri setini arttırmayı amaçlayan bir augmentation yöntemidir. Şekil 8’de mosaic yöntemi ile artırılmış bir örnek bulunmaktadır.



Şekil 8 Mosaic Augmentation Yöntemi

2.2.2-) Copy Paste


Copy Paste augmentation yönteminde veri setinde bulunan fotoğrafların kopyalanarak başka bir resime yerleştirilmesi ile veri setini arttırmayı amaçlayan bir augmentation yöntemidir. Şekil 9'da **Copy Paste** yöntemi ile arttırılmış bir örnek bulunmaktadır.



Şekil 9 Copy Paste Augmentation Yöntemi

2.2.3-) MixUp


MixUp augmentation yönteminde veri setinde bulunan fotoğrafların birbiri ile birleştirilmesi ile veri setini arttırmayı amaçlayan bir augmentation yöntemidir. Şekil 10'da **MixUp** yöntemi ile arttırılmış bir örnek bulunmaktadır.



Şekil 10 MixUp Augmentation Yöntemi

2.2.4-) Augment HSV

Augment HSV augmentation yönteminde veri setinde bulunan fotoğrafların Konstrat,doygunluk ve parlaklık gibi değerleri değiştirerek veri setini arttırmayı amaçlayan bir augmentation yöntemidir. Şekil 11'de **Augment HSV** yöntemi ile arttırılmış bir örnek bulunmaktadır.



Şekil 11 Augment HSV Augmentation Yöntemi

2.3 HiperParametreler

YOLOv5 nesne tespit algoritmasını eğitirken modelin doğruluk oranı ile senkronizeli bir şekilde çalışan çeşitli parametreler belirlenmiştir. Bu parametrelerin belirlenmesi ile model eğitimi sırasında modelin başarı durumuna göre çeşitli artırma teknikleri yapılacaktır. Böylelikle modelin **etkileşimli** bir eğitim süreci yaşaması sağlanacak ve model doğruluğunun artması sağlanacaktır. Belirlenen parametreler arasında yukarıda açıklamaları verilen artırma teknikleri, Başarı için gereken iou threshold değeri gibi çeşitli parametreler belirlenmiştir. Bu parametreler şekil 12’de verilmiştir.

```
fl_gamma: 0.0 # focal loss gamma (efficientDet default gamma=1.5)
hsv_h: 0.015 # image HSV-Hue augmentation (fraction)
hsv_s: 0.7 # image HSV-Saturation augmentation (fraction)
hsv_v: 0.4 # image HSV-Value augmentation (fraction)
degrees: 0.0 # image rotation (+/- deg)
translate: 0.1 # image translation (+/- fraction)
scale: 0.9 # image scale (+/- gain)
shear: 0.0 # image shear (+/- deg)
perspective: 0.0 # image perspective (+/- fraction), range 0-0.001
flipud: 0.0 # image flip up-down (probability)
fliplr: 0.5 # image flip left-right (probability)
mosaic: 1.0 # image mosaic (probability)
mixup: 0.1 # image mixup (probability)
copy_paste: 0.1 # segment copy-paste (probability)

lr0: 0.01 # initial learning rate (SGD=1E-2, Adam=1E-3)
lr_f: 0.1 # final OneCycleLR learning rate (lr0 * lr_f)
momentum: 0.937 # SGD momentum/Adam beta1
weight_decay: 0.0005 # optimizer weight decay 5e-4
warmup_epochs: 3.0 # warmup epochs (fractions ok)
warmup_momentum: 0.8 # warmup initial momentum
warmup_bias_lr: 0.1 # warmup initial bias lr
box: 0.05 # box loss gain
cls: 0.3 # cls loss gain
cls_pw: 1.0 # cls BCELoss positive_weight
obj: 0.7 # obj loss gain (scale with pixels)
obj_pw: 1.0 # obj BCELoss positive_weight
iou_t: 0.20 # IoU training threshold
anchor_t: 4.0 # anchor-multiple threshold
# anchors: 3 # anchors per output layer (0 to ignore)
fl_gamma: 0.0 # focal loss gamma (efficientDet default gamma=1.5)
hsv_h: 0.015 # image HSV-Hue augmentation (fraction)
hsv_s: 0.7 # image HSV-Saturation augmentation (fraction)
hsv_v: 0.4 # image HSV-Value augmentation (fraction)
```

Şekil 12 HiperParametreler

2.4 Donanımlar

Eğitim ve test sırasında kullanılan donanımlar optimize yapay zeka modellerinin eğitilebilmesi için detaylıca belirlenmiştir. Aşağıda belirtilen eğitim için kullanılacak donanımlar ile hızlı bir şekilde model eğitimi sağlanmıştır. Şekil 13’de bulunan donanımlar eğitim için kullanılmıştır. Eğitim sırasında kullanılmış RTX 3070 Ti ekran kartının model eğitiminde büyük katkı sağladığı belirlenmiştir. Ayrıca 64 GB Ram sayesinde veriler için ön bellek oluşturulmuş ve eğitimin hızlandırılması sağlanmıştır.

Kullanılan Donanımlar	EĞİTİM
İşlemci (CPU)	12th Gen Intel Core i7-12700K
Ekran Kartı (GPU)	Nvidia Geforce RTX 3070 Ti
Ram	64 GB

Şekil 13 Eğitim İçin Kullanılan Donanımlar


2.5 Eğitim İşlemi

HiperParametreler ayarlandıktan sonra eğitilecek YOLOv5 pretrained modeli belirlenmiştir. YOLOv5 pretrained model olarak yüksek başarı oranı nedeniyle YOLOv5X alt modeli tercih edilmiştir. Eğitilecek YOLOv5 modeli belirlendikten sonra YOLO formatına getirilen veri belirlenmiş YOLOv5X modeline girdi olarak girilmiş ve modeli öğrenmesi sağlanmıştır. Model eğitim süresince augmentation işlemleri hiperparametreler ile sürdürülmüştür. Model eğitimi Python programlara dilinde yerel (local) olarak RTX 3070 Ti Ekran Kartlı bilgisayar üzerinden gerçekleştirilmiştir.

3-) Sonuçlar ve İnceleme (30 puan)

3.1 Model Doğruluğu


Sağlık Bakanlığı tarafından sağlanan veri seti %70 Eğitim (Train) %20 Test ve % 10 Validation olmak üzere 3 parçaya ayrılmıştır. Bir önceki aşamada eğitilen model toplam veri setinin %70'i ile eğitilmiştir. Veri Seti 3 parçaya ayrılırken verilerin tüm bulguları içermesine yani homojen ve rastgele bir şekilde ayrılmasında dikkat edilmiştir. Eğitimi için kullanılan veri seti dışında kalan %30'luk bölüm ile de modelin doğruluğu belirlenmiştir. Modelin doğruluğu için ilk olarak veri setinin %70'i ile eğitilen modelin validation veri seti üzerindeki loss, iou, map skorları tablolar şeklinde elde edilmiştir. Bu tablolar Şekil 14'de verilmiştir. Bu tablodaki maP(mean average precision) değeri modelin tahmin ettiği sonuçları doğru sonuçlarla karşılaştırımı(Jaccard Indexi) ile ortaya çıkan iou değeridir. Bu nedenle maP değeri model doğruluğu için önemli bir parametredir. Bu tabloda başarı eşiği 0.5 olarak ayarlandığında modelin doğruluğu yüzde 66-67 olarak belirlenmiştir. maP değerinin yanında model doğruluğu için önemli olan precision, recall, loss gibi parametreler incelendiğinde sağlıklı bir eğitimin gerçekleştiği herhangi bir ezberleme (overfitting) durumunun olmadığı belirlenmiştir. Ayrıca modelin hassasiyet değerlerine bakılınca modelin daha da geliştirilmesi durumunda gerçek yaşama uygun bir system olabileceği belirlenmiştir. Model doğruluğunun arttırımı için çalışmalar devam etmektedir. Final Yarışmasında kadar model doğruluğunu transfer learning ile başka verilerin kullanımı, hiperparametrelerin arttırımı, model birleşimi gibi çeşitli tekniklerle %80 seviyelerine arttırmayı planlamaktayız.




Şekil 14 Model Doğruluğu

Elde edilen YOLOv5X modeli validation için ayrılan veri seti dışında hiç görmediği ve toplam veri setinin %20'sini oluşturan test veri seti ile test edilmiştir. Yapılan testler sonucunda elde edilen F1, precision, recall, confidence gibi skorlar ve bu skorların birbirleri arasındaki sınıf sınıf korrelasyonları Şekil 15 ve 16'da verilmiştir. Test veri seti üzerinde yapılan testlerde başarı eşiği iou değeri %60 olacak şekilde ayarlanmıştır. Başarı eşiği %60 gibi yüksek bir değer olarak ayarlanmasına rağmen doğruluk oranı (maP) %60 civarı elde edilmiştir. Elde edilen skorlar yorumlanınca sağlıklı bir eğitim gerçekleştiği belirlenmiştir. Ayrıca sınıf sınıf F1 score, confidence gibi değerlere bakılınca en yüksek skor %96 ile Abdominal aort diseksiyona aitken en düşük skor %23 ile Akut Apandisit ait olduğu tespit edilmiştir. Abdominal aort diseksiyona sınıfına ait toplamda 9823 bulgu bulunmaktadır. En fazla örnek olan sınıfta elde edilen %96 doğruluk başarısı kritil bir öneme sahiptir. Akut apandisit sınıfındaki düşük başarının(%23)

sebebi olarak veri setindeki Akut Apandisit ait bulguların küçük olmasından kaynaklandığı belirlenmiştir. Bunun sonucunda akut apandisit sınıfına ait F1 Score ve confidence gibi değerleri final yarışmasına arttırmak için çalışmaya başlanmıştır. Modelin test edildiği %20'lik veri setini daha önce hiç görmediği düşünüldüğünde elde edilen modelin umut vadeden bir model olduğu düşünülmektedir.



Şekil 15 Model Doğruluk Oranları(F1 Score)



Şekil 16 Model Doğruluk Oranları

3.2 Yaşanan Sorunlar


Yukarıda doğruluk değerleri verilen YOLOv5 modeli eğilirken çeşitli sorunlarla karşılaşmıştır. Bu sorunların başlıcalarından örnek olarak eğitim işleminin yavaş bir şekilde gerçekleşmesi verilebilir. Yüksek boyutlu bir veri seti ile çalışıldığı için model eğitiminin yavaş bir şekilde belirlenmiştir. Bu sorunu çözmek için ilk olarak model seçiminde YOLOv5x modeli yerine YOLOv5s modeli seçilmiştir. Sorun nispeten çözülmüş olsa da doğruluk oranı düştüğü için bu çözümden vazgeçilmiştir. Nihai çözüm olarak yüksek RAM miktarına sahip bilgisayarlar kullanarak veri setinin ön belleğe alınması sağlanmış ve böylelikle ciddi miktarda hız artışı sağlanmıştır. Ayrıca yaşanan bir diğer soruna örnek olarak modelin doğruluk oranının yüzde 40 civarında takılı kalması verilebilir. Model eğitimi süresince modelin mAP skorunun %40 civarlarında takılı kaldığı belirlenmiştir. Bu sorunla başa çıkmak için hiperparametreleri augmentation teknikleri kullanılmış bunun sonucunda ise modeli doğruluğunun %67 civarında elde edilmiştir.

4-) Deney ve Eğitim Aşamalarında Kullanılan Veri Setleri (15 puan)

Nesne Tespit (Object Dedection) modeli eğitilirken Sağlık Bakanlığı tarafından sağlanan bilgisayarlı tomografi (CT) görüntüleri kullanılmıştır. Sağlık bakanlığına ait bu veri seti elde edilirken takım üyeleri tarafından Kurumsal Gizlilik Tahaattütname belgeleri imzalanmıştır. Nesne Tespit (Object Dedection) modeli eğitim sürecini hızlandırmak için şu anda sadece Sağlık Bakanlığı tarafından sağlanan veriler kullanılmıştır. İlerleyen süreçte Sağlık Bakanlığı verileri ile elde edilen modele transfer learning yöntemi ile farklı kaynaklardan elde edilecek verilerin modele girdi olarak girilmesi ve modelin öğrenmesi planlanmaktadır.


4.1 Veri Seti Analizi

Sağlık Bakanlığı tarafından verilen bilgisayarlı tomografi(CT) verilerinin analizi yapılmıştır. Yapılan analizlerde hangi bulgulardan ne kadar olduğu, görülme yoğunlukları tablo haline getirilmiştir. Şekil 17’de görülen bulguların sayısına ait grafik bulunmaktadır. Bu grafik incelendiğinde Şartname Sınıfı 1 olan bulgudan 5991 tane, Şartanem Sınıfı 2 olan bulgudan 1152 tane, Şartname Sınıfı 3 olan bulgudan 7121 tane, Şartname Sınıfı 4 olan bulgudan 2768 tane, Şartname Sınıfı 5 olan bulgudan 1152 tane ve Şartname Sınıfı 6 olan bulgudan da 9823 tane örnek olduğu belirlenmiştir.



Şekil 17 Bulguların Sayısı

Şekil 18’de ise bilgisayarlı tomografi(CT) görüntülerinde bulunan bulguların koordinatlarının bulunduğu yoğunluk haritası, bulguların yüksekliği, genişliği ve tüm bu özelliklerin korelasyonuna ait grafik bulunmaktadır. Bu grafiğin eldesi ile bulguların çoğunun orta büyüklükte olduğu ve genellikle Bilgisayarlı tomografi görüntülerinin ortalarına yakın olduğu tespit edilmiştir. Bu analizin elde edilmesi ile veri seti sağlık bakanlığı tarafından verilen veri seti hakkında detaylı bilgi sahibi olunmuştur. Bu tablo bilgisayarlı tomografi görüntüleri için oluşturulan etiketler kullanılarak açık kaynak kodlu kütüphaneler ile oluşturulmuştur.



Şekil 18 Yoğunluk Haritası

Yapılan Veri Seti Analizleri sonucunda veri setinin homojen dağılmadığı ve bulguların çoğunun küçük yapıları olduğu belirlenmiştir. Veri Setini dengelemek için uygulanacak Veri Seti Arttırma Yöntemi belirlenmiştir. Belirlenen yöntem ile dengeli bir veri seti elde etmek amaçlanmıştır.

5-) Referanslar (5 puan)

1-) YOLOv5 compared to Faster RCNN. Who wins?

<https://towardsdatascience.com/yolov5-compared-to-faster-rcnn-who-wins-a771cd6c9fb4>

2-) Kim, S., Yoon, H., Lee, MJ. et al. Performance of deep learning-based algorithm for detection of ileocolic intussusception on abdominal radiographs of young children. *Sci Rep* 9, 19420 (2019). <https://doi.org/10.1038/s41598-019-55536-6>

3-) Jacobzon, G. (2020). Multi-site Organ Detection in CT Images using Deep Learning (Dissertation). Retrieved from <http://urn.kb.se/resolve?urn=urn:nbn:se:kth:diva-279290>

4-) Song K. D. (2021). Current status of deep learning applications in abdominal ultrasonography. *Ultrasonography (Seoul, Korea)*, 40(2), 177–182. <https://doi.org/10.14366/usg.20085>

5-) YOLOv5  in PyTorch > ONNX > CoreML > TFLite

<https://github.com/ultralytics/yolov5>

6-) YOLOv5 (6.0/6.1) brief summary, 2022, Erişim Adresi: <https://github.com/ultralytics/yolov5/issues/6998>