

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için

Hastalık Tespiti Kategorisi)

PROJE DETAY RAPORU

TAKIM ADI: AI-STAR

TAKIM ID: 365890

İçindekiler

1. Proje Mevcut Durum Değerlendirmesi	1
2. Özgünlük.....	2
3. Sonuçlar ve İnceleme	3
4. Deney ve eğitim aşamasında kullanılan verisetleri.....	6
5. Referanslar	7

1. Proje Mevcut Durum Değerlendirmesi (20 puan)

Projemizde, proje sunuş raporunda belirtilen algoritmalarından Faster R-CNN derin öğrenme modeli Sağlık Bakanlığı tarafından tarafımıza sağlanan veriler üzerinden eğitimi gerçekleştirebilmesi ve doğru sonuca ulaşabilmesi için planlama ve araştırma gerçekleştirdik. Faster R-CNN modeli Pascal VOC formatı ile doğru şekilde çalışmaktadır[1]. Bu yüzden Sağlık bakanlığı tarafından sağlanan verileri, dataset modeline çevirme işlemini gerçekleştirdik. Ayrıca çalışmamızın daha başarılı sonuçlar vermesi için Sağlık Bakanlığı'na benzer verisetleri Kaggle, Google Opendataset gibi platformlardan araştırdık ve benzer olan verisetlerini çalışmamıza, Sağlık Bakanlığındaki verisetinin formatına benzer olacak şekilde düzenleyerek ekledik.

Projemizde Faster R-CNN derin öğrenme modelini kullanabilmek için Google tarafından Tensorflow Derin Öğrenme kütüphanesini[2] tercih ettik. Tıbbî görüntüler üzerinde çalışacağımızdan Tensorflow'un GPU versiyonunu kullandık. Tensorflow GPU versiyonunun çalışabilmesi için CUDA destekli bir ekran kartına sahip bir donanımın olması gerekmektedir. Bu yüzden buna uygun olarak Nvidia 4GB GT1050ti Ekran Kartlı, 24 GB RAM Belleğe sahip bir bilgisayar donanımını modelimizi eğitmek için kullandık.

Başarı oranını artırmak için veri setlerimiz üzerinde Data Augmentation yöntemlerini kullandık. Bunun için Python programlama dilinde kullanılabilen Albumentations kütüphanesini kullandık [3].

Sağlık Bakanlığı tarafından sağlanan BT görüntüleri DICOM uzantılı olduğundan Python'da bu görüntüleri dönüştürmeden kullanmamızı sağlayacak SimpleITK kütüphanesini

çalışmamızda kullandık[4].


Veriler üzerinde gerekli düzenlemeleri yaptıktan sonra, eğitim için kullanılacak Faster R-CNN[1] modelinin eğitim için gerekli ayarlamaları yaptık. Modelin eğitimi için adım sayısı olarak 120 bin adım belirledik. Sağlanan veriler büyük boyutta olduğundan eğitim aşaması uzun sürmüştür. Eğitimle ilgili ekran görüntüsü aşağıda verilmiştir.

2. Özgünlük (30 puan)

Sağlık Bakanlığının verisetinin dışında veriseti dahil etmek için Kaggle ve Google Opendataset gibi platformlarda tarama gerçekleştirilmiştir. Fakat sağlıklı bir Abdomen görüntüsü bulunamamıştır. Bu yüzden Sağlık Bakanlığının sağladığı veriseti üzerinde veri artırımı (data augmentation) yöntemleri kullanılarak eğitim veri seti artırılmıştır. Bunun da başarı oranına olumlu etki oluşturması beklenmektedir.


Ayrıca Faster R-CNN modeli için Xpection konfigürasyonu üzerinde sağlık verisi üzerinde çalışılması nedeniyle değişiklikler yapılarak daha doğru bir sınıflandırma yapılması hedeflenmiştir.

Projenin aşamaları ve uygulanması aşağıdaki şekilde gösterilmiştir.



3. Sonuçlar ve İnceleme (30 puan)

Faster R-CNN modelinin eğitimi sırasında Tensorflow'un Tensorboard ekranı sayesinde her bir adımda oluşan loss function değeri anlık olarak takip edilebilmektedir. Bu sayede eğitimin ne kadar başarılı olabileceği öngörülmektedir. Loss function değeri azaldıkça modelin eğitiminin başarılı olma ihtimali artmaktadır. Eğitimin ilk adımlarında Loss function değeri yüksek iken eğitimin sonuna doğru minimum seviyeye inmektedir. Eğer bu değer azalmıyorsa eğitimi devam ettirmenin herhangi bir faydası olmayacaktır. Eğitim sonunda oluşan Adım sayısı – Loss function değeri grafiği aşağıda gösterilmiştir.



Eğitim aşaması bittikten sonra geliştirilemn modelin başarısını ölçmek için eğitimde kullanılmayan test veri seti üzerinde bir sınaıa işlemi gerçekleştirilmiştir. Sınama yapılan BT görüntülerinden örnek bir hastalık tespit sınaıa görüntüsü aşağıda gösterilmiştir.



Şekil 2. Örnek Tespit

Test işlemi sonucunda oluşan test resimleri analiz edilmiş ve 2 sütundan oluşan bir tabloya aktarılmıştır. Beklenen ve tahmin değeri sütunlarından oluşan bu tablo daha sonra aşağıda tablo halinde verilen konfüsyon matrisine dönüştürülmüştür.

Konfüsyon matrisi elde edildikten sonra öncelikle tp,tn,fp ve fn değerleri ortaya çıkartılmıştır. Daha sonra her sınıf için precision,recall, f skoru değerleri hesaplanmıştır. Çalışmamızda bu hesaplamalar için kullanılan formüller aşağıda verilmiştir[5].

$$Precision = \frac{TP}{TP + FP} \quad (1)$$

$$Recall(Sensitivity) = \frac{TP}{P} \quad (2)$$

$$F - measure = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (3)$$

$$Accuracy(Doğruluk) = \frac{TP + TN}{P + N} \quad (4)$$

$$Specificity = \frac{TN}{TN + FP} \quad (5)$$

Tablo 1. Konfüsyon Matrisi

	Aorta Anevrizma	Akut Apandiks	Bulgu Yok	Akut Divertikülit	Pankreas İltihabı	Safra Kesesi İltihabı	Üreter Taşı
Aorta Anevrizma	44	0	3	1	1	0	1
Akut Apandiks	0	47	1	0	1	2	0
Bulgu Yok	0	2	21	0	0	0	2
Akut Divertikülit	1	0	2	43	0	0	4
Pankreas İltihabı	0	1	1	0	44	4	0
Safra Kesesi İltihabı	0	1	4	0	3	42	0
Üreter Taşı	0	0	2	1	0	1	46

Konfüsyon matrisi oluşturulduktan sonra her sınıf için TP, FP, TN, FN, Recall, Precision, Specificity ve F-skoru hesaplanmıştır. Bu hesaplamalar sonucu oluşan değerler Tablo 2 'de gösterilmiştir. Çalışmanın genel performansını ölçmek için de genel doğruluk, genel hata ve Cohen's Kappa [6] değerleri hesaplanmıştır.

Tablo 2. İstatiksel Sonuçlar

Sınıf adı	TP	FP	TN	FN	Recall	Precision	Specificity	F-Skor
Aorta Anevrizma	44	1	275	6	88,00%	97,78%	99,64%	92,63%
Akut Apandiks	47	4	271	4	92,16%	92,16%	98,55%	92,16%
Bulgu Yok	21	13	288	4	84,00%	61,76%	95,68%	71,19%
Akut Divertikülit	43	2	274	7	86,00%	95,56%	99,28%	90,53%
Pankreas İltihabı	44	5	271	6	88,00%	89,80%	98,19%	88,89%
Safra Kesesi İltihabı	42	7	269	8	84,00%	85,71%	97,46%	84,85%
Üreter Taşı	46	7	269	4	92,00%	86,79%	97,46%	89,32%
Genel Doğruluk							88,04%	
Genel Hata							11,96%	
Cohen's kappa							85,99%	

4. Deney ve eğitim aşamalarında kullanılan veri setleri (15 puan)

Projenin deney ve test aşamasında Sağlık Bakanlığı tarafından sağlanan veriseti kullanılmıştır . Bunun dışında Kaggle ve Google Open Datasets platformları üzerinden Abdomen CT DICOM görüntüleri taranmış fakat sağlıklı veriler elde edilememiştir. Bu nedenle

bu veriler üzerinde data augmentation yöntemleri kullanılarak veri sayısı artırılmıştır. Test aşaması için verisetindeki 350 DICOM görüntüsü eğitime dahil edilmemiş ve test için kullanılmıştır. Diğer veriler de Faster R-CNN'in eğitimi için verilerin %80'i training %20'si validation olarak ayrılmıştır.

5. Referanslar (5 puan)

- [1] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN : Towards Real-Time Object Detection with Region Proposal Networks," pp. 1–14, 2016.
- [2] Tensorflow, "Why TensorFlow." 2019. Accessed: Dec. 01, 2019. [Online]. Available: <https://www.tensorflow.org>
- [3] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and Flexible Image Augmentations," *Information*, vol. 11, no. 2, p. 125, Feb. 2020, doi: 10.3390/info11020125.
- [4] B. Lowekamp, D. Chen, L. Ibanez, and D. Blezek, "The Design of SimpleITK," *Frontiers in Neuroinformatics*, vol. 7, 2013, doi: 10.3389/fninf.2013.00045.
- [5] Y. Liu, Y. Zhou, S. Wen, and C. Tang, "A strategy on selecting performance metrics for classifier evaluation," *International Journal of Mobile Computing and Multimedia Communications (IJMCMC)*, vol. 6, no. 4, pp. 20–35, 2014.
- [6] T. O. Kvålseth, "Note on Cohen's kappa," *Psychol Rep*, vol. 65, no. 1, pp. 223–226, 1989.

