

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için

Hastalık Tespiti Kategorisi)

PROJE DETAY RAPORU

TAKIM ADI: SÜÜÜ

TAKIM ID: 374192

İÇİNDEKİLER:

Proje Mevcut Durum Değerlendirmesi..... 3

Özgünlük 7

Sonuçlar ve İnceleme 9

Kullanılan ek verisetleri 10

Referanslar 10



Batın BT lerinde akut batın tespit ve sınıflanmasında, 3D bağlam ve alan bilgisi ile donatılmış, patolojiye özel çapalarla eğitilmiş yapay zeka aracılı nesne tespit sistemi:

Veriden öğrenen bir sistem geliştirirken ilk yapılması gereken verinin iyi anlaşılmasıdır. Bu amaçla veri gürültüden arındırıldıktan sonra EDA (araştırmacı veri analizi) ile verinin özellikleri incelenmelidir. Bu amaçla önce verimizin sınıf dağılımını görmek istedik.

	HASTA SAYISI	KESİT SAYISI
AORTA	159	9817
APENDİSİT	221	5852
DİVERTİKÜLİT	76	1148
KOLESİSTİT	124	4925
PANKREATİT	146	6923
ÜRİNER	283	2556

Tablo 1: Verinin sınıf dağılımı

Bu tabloya baktığımızda birkaç önemli şey dikkatimizi çekmekte. Her şeyden önce en çok sayıda kesit sayısına sahip aort patolojisi ile en az sayıda kesit sayısına sahip divertikülit örnekleri arasında 1:10 luk ve üriner taş örnekleri arasında 1:4 lük bir sınıf dengesizliği sorunu mevcut. Apendisit, kolesistit ve pankreatit birbirine yakın sayıda örnekler içermekte ve bu sınıflarda sınıf dengesizliği 1:2 nin altına düşmektedir. Bir başka dikkatimizi çeken şey, en fazla hasta sayısına sahip üriner taşın en az 2. sayıda örneğe sahip olmasıdır. Öte yandan en az 3. sayıda hasta sayısına sahip aorta patolojisi en fazla örneğe sahiptir. Bu durum aslında patoloji bilgimiz ile uyum içindedir. Çünkü üriner taşların çok küçük, divertikülit ve apandisit biraz daha büyük, kolesistit, pankreatit ve aort patolojilerinin ise en büyük hacmi kaplaması beklenen bir durumdur. Gerçekten de aorta için hasta başına ortalama 60 kesit patolojik olarak izlenirken taş için bu 9 a inmektedir. Çift sınıflı durumlar tablo ile tartışılmıştır. (Tablo 2).


```
Out[335]: {'ao_ur': 14,
          'ao_pank': 2,
          'ao_kol': 0,
          'ao_div': 1,
          'ao_ap': 0,
          'ur_pank': 6,
          'ur_kol': 7,
          'ur_div': 8,
          'ur_ap': 14,
          'pankr_kol': 9,
          'pankr_div': 0,
          'pankr_ap': 1,
          'kol_div': 0,
          'kol_ap': 1,
          'div_ap': 0}
```

Tablo 2: Birden fazla sınıfın bir arada olduğu durumları incelediğimizde ise aslında birden fazla sınıf içeren durumlarda büyük oranda ana patolojiye üriner taşın eşlik ettiğini görmekteyiz. Gerçekten de 63 çok sınıflı hastanın 49 unda ikinci sınıf üriner taşlara aitti ve üriner taş her sınıf ile beraber birliktelik göstermekte idi. Bunun dışında 9 vakada kolesistit ile pankreatit, ortak etyolojiden kaynaklandığı için beklediği gibi beraberlik göstermekte idi. Diğer birliktelikler yok sayılacak kadar az idi.

Öte yandan BB lerin analizi de önemli bilgiler verebilmektedir. Bu amaçla her sınıf için BB lerin uzunluk, genişlik ve aspect oranlarını hesapladık. Hesapladığımız değerleri tablo ve histogram olarak sunduk (Tablo 2, Resim 1).

	Aorta	Apend	Kolesist	Pankr	Diver	Uriner
Width_mean	43.334827	70.095694	43.947614	42.876932	87.760453	76.783255
Width_max	354.000000	184.000000	145.000000	192.000000	329.000000	218.000000
Width_min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Width_std	34.377863	39.763996	32.437149	32.334069	58.910544	44.717781
Height_mean	44.422329	68.331511	46.833299	57.096923	91.073171	76.697183
Height_max	354.000000	185.000000	153.000000	218.000000	317.000000	216.000000
Height_min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Height_std	35.039646	40.567099	32.498435	38.731530	57.762700	44.253032
Aspect_mean	1.251772	1.121642	1.251772	1.121642	1.251772	1.121642
Aspect_max	39.000000	23.000000	39.000000	23.000000	39.000000	23.000000
Aspect_min	0.025641	0.052632	0.025641	0.052632	0.025641	0.052632
Aspect_std	1.698571	0.774602	1.698571	0.774602	1.698571	0.774602

Tablo 3: 6 sınıf için BB genişlik, yükseklik ve aspect oranının max, min, ortalama ve standart sapma değerleri




Resim 1a) BB genişliklerinin sınıf bazlı beraber histogramı

1b) BB genişliklerinin her bir sınıf için ayrı ayrı histogramları. Sırasıyla üst satır aorta, apendisit, kolesistit alt satır pankreatit, divertikülit ve üriner taş aittir.

Kesit sayısı dağılımındaki benzer bir trend ile aorta kesitlerindeki aksiyel BB genişlik ve yüksekliklerinin en büyük, taş ve divertikülit de ise en küçük olduğu izlenmektedir. Ortalama aspect oranları tüm sınıflar için 1.2 ile 1.4 arasında değişmektedir. Bu bilgiler daha sonra BB çapa büyüklüğü ve aspect oranı belirlemek için yönlendirici olacaktır.


Öte yandan tüm BB leri axiyel düzleme agrege ederek spatial lokasyon kümelenmelerini görmek istedik (**Resim 2**).



Resim 2: Sırasıyla üst satır aorta, apendisit, pankreatit, alt satır, kolesistit, divertikülit, üriner taş.

Isı haritalarını incelediğimizde BB lerin aksiyel 2D projeksiyonlarının anatomi, anatomik olasılık ve patoloji genişliği ön bilgilerini takip ettiği görülmekte. Hakikaten apandisit ve kolesistit BB leri anteriorda, pankreatit BB leri daha geniş dağılımda orta hatta izlenmektedir. Divertikülit BB lerinin yaygın ve anguler görünmesinin sebebi, dataya ulaşımındaki sorunumuz nedeniyle, bazı hastaların görüntülerinin sistemimize yüklenememiş olması bunların büyük kısmının divertikülit vakaları olması bu nedenle az sayıda divertikülit BB sinin agrege edilebilmiş olmasıdır.

BB agregasyon ısı haritalarının değerlendirilmesi daha önceki anatomik kısıtlı lokalizasyon olasılığı hipotezimizi desteklemektedir (Resim 3).



Resim 3: Tanımlanan patolojilerin beklenen sahalarının sagittal ve koronal düzleme projeksiyonu. Aslında supero-inferior, antero-posterior ve sol-sağ gradient bir arada kullanıldığında her patoloji sadece bir kombinasyona uymakta. Örneğin üst ant sağ kolesistit için alt ant sağ apendisit için zorunlu lokasyon haline gelmektedir.

BB anatomik beklenen yerleri, elimizdeki BB lerin agregasyonu, BB büyüklük ve aspect oranlarının analizi sonrası son olarak olası dansite değerleri dağılımı da ek bilgi sağlayabilecektir. Bu amaçla dansite değerlerinin analizinde pankreatit, kolesistit, divertikülit ve apandisit daima 50 HU nun altında, üriner taşın daima 100 HU nun üstünde aorta patolojisinin ise kontrast verilip verilmemesine bağlı olarak değişken olduğu hiçbir patolojinin 0 HU nun altında bir değer içermediğini gördük. Bu da görüntülerimizin dansite değerleri için kısıtlama yapabilmemiz anlamına geliyordu.

Önişleme:

Verinin analizi sonrası, bu veriyi işleyebilmek için bir takım ön işlemler yapılması gerekli idi. Bu amaçla önce metadata bilgilerini kullanarak 2x2x2 mm ortak rezolusyona resample işlemi yaptık. Görüntü büyüklüklerini 256x256 piksel boyutlara fixe ettik. Küçük kalanları pad, büyük gelenleri crop işlemi ile bu boyuta uydurduk. Yine metadata'dan Recon Slope ve Intercept değerlerini alarak dansite değerlerini ortak HU skalasına çevirdik. 0-255 arası dansite değerlerini tutarak kalanını clip ile attık. Bu bize ilgilendiğimiz dansite aralığında kalmamızı sağlayacak öte yandan modele ilgilenmesi gereken piksel aralığını sınırlayarak ek katkı sağlayacak idi.

BB ler patolojinin olduğu bölgenin kaba bir değerlendirmesini sağlamakta olup çevredeki normal sinyalin de bir miktar kontamine olmasına izin vererek modelin kafasını karıştırabilmektedir. Bu nedenle ek segmentasyon maskelerinin verilmesi modelin doğru sinyali daha iyi anlayabilmesi açısından fayda sağlayacaktır. Buna istinaden her gruptan 10'ar hastayı Radyoloji uzmanımız 3D Slicer programı Grow from Seed modülü ile 3 boyutlu segmente etmiştir (1). Bu 10'ar hasta için segmentasyon haritaları modele ayrı olarak verilmiş diğer hastalar için ise model BB' lerin içini doldurarak kaba segmentasyon haritalarını kendi, yaratarak kullanmıştır.

Model ve eğitimi:

Model olarak Mask-RCNN mimarisi Matterpott implementasyonu ile kullanılmıştır (2). Modelin öznitelik çıkarıcı kısmı olarak ResNet 101 mimarisi kullanılmış model ağırlıkları COCO veri-setindeki ön eğitilmiş hali ile başlatılmıştır. Input olarak ilgilenilen kesit ile beraber bir önü ve bir arkası olarak 3 kanallı giriş hazırlanmış böylece 3D bağlam korunmaya çalışılmıştır. Ardından kendi verisetimizdeki normal görüntüler ve LİTS ve KİTS verisetleri ile bir AutoEncoder eğitilmiş ve modelin abdominal BT piksel dağılımını öğrenmesi sağlanmıştır (3,4). Ardından AE' nin encoder tabakasının ağırlıkları transfer edilmiş ve MaskRCNN (5) bu eğitilmiş ağırlıklar ile başlatılmıştır.

Kendi çıkardığımız segmentasyon haritaları modele verilmiş kendi çıkardıklarımız dışında kalanlar için ise uzun aksı x uzunluğu kısa aksı y uzunluğu olan santralize elipsler ile psödo-maskler oluşturularak modele verilmiştir.

BB analizinden elde ettiğimiz veriler ışığında BB size olarak [10, 30, 50] ve aspect ratio olarak [1, 1.2, 1.4] modele verilmiştir.

Bu tartışmalar ışığında proje sunuş raporunda tartışılan ve tıbbi nesne tespiti alanında en yüksek başarımları gösteren modellerin kullandığı stratejilere kendi bakış açımızı da katarak oluşturduğumuz 3D bağlamın korunması, benzer veri-setleri ile ön eğitim yaparak ağırlıkların veri-setimize uygun hale getirilmesi, belli sayıda segmentasyon maskesi ve kalanları psödomask olmak üzere modele gürültüden daha fazla ayrılmış sinyalin verilmesi, veri setine uygun çapa büyüklük, oran ve aspect oranlarının tespit edilerek modele verilmesi, dansite değerlerinin hedef aralığa çekilerek alan bilgisinin aktarılması aşamaları planlandığı şekilde yapılmıştır (6-12). Spatial bilginin ön bilgi olarak alana injekte edilmesi işlemi ile farklı backbone lar ile çalıştırarak elde edilen sonuçlar arasında majority vote ya da ağırlıklandırılmış füzyon şeklinde birleştirilme yapılması ise önümüzde kalan 1 aylık sürede gerçekleştirilmeye çalışılacaktır.

Özgünlük:

Objektif tespit problem literatürde sık çalışılmış ve oldukça başarılı sonuçlar elde edilmiş bir bilgisayarlı görü problemidir. Buna istinaden geniş kabul görmüş ve büyük veri setleri ile eğitilmiş YOLO ailesi, Mask-RCNN, Detectron, DETR, RetinaNet gibi oturmuş modeller mevcuttur. Elimizdeki veri sayısını kısıtlılığı göz önüne alındığında en akılcı yol bu oturmuş ve iyi eğitilmiş ağlar ile transfer yöntemi ile model eğitime başlamak idi. Bu hemen her takımın yapacağı standart bir yöntem olacağı için bu şekilde sonuçların birbirine yakın olmasına çok şaşırmamak gerekir. Farklı belirleyecek olan, farklı ön işleme, son işleme, hiperparametre seçimi, ensemble geliştirme ve alan bilgisinin farklı yönlerinin modele ön bilgi olarak verilmesi olacaktır. Biz de bu basamakların her biri için kendi özgün yöntemlerimizi kullandık. En önemli katkılarımız ise segmentasyon haritaları eklemenin ve alan bilgisi yerleştirmenin daha da geliştirilmesi şeklinde olacaktır. Şöyle ki segmentasyon maskesi oluşturmanın ve bunu da öğrenme algoritmasına dahil etmenin güçlü katkıları önceki çalışmalarda belirtilmiştir. Ancak bu haritaları oluşturmak için ellerinde RECIST ölçümleri bir excel dosyası olarak mevcut idi. Bizim elimizde böyle bir veri olmadığı için başka şekilde bu problemi aşmaya çalışacağız. Bunun için kullandığımız ve kullanacağımız yöntemler:

1. Segmentasyon haritaları sağlanması

Takım kaptanımız aynı zamanda radyoloji uzmanı da olduğu için verilen görüntülerin bir alt kümesini hızla segmente ederek sınıf başına 10'ar hasta için segmentasyon haritaları hazırladı bu modele her sınıf için gürültüden arındırılmış sinyal verilmesini sağladı.

Diğer hastalar için ise verilen kutuların uzun ve kısa kenarlarını bir elipsin uzun ve kısa kenarlarına eşleyerek elipsler oluşturularak kaba maske olarak kullanıldı.

2. 3D bağlamın korunması: modele ilgilendiği anatominin farkında olmasını sağlayarak bağlam bilgisini korudu

3. LITS ve KITS verisetleri ile kendi modelimizdeki görüntüler kullanılarak ilgilenilen anatomiye spesifik ağırlıkların öğrenilmesi sağlandı. Bunun için AE eğitimi yapıldı. Böylece hem modelin COCO veriseti üzerindeki öğrenmiş olduğu ağırlıklardan hem de çalışacağı domain e spesifik ağırlıklardan faydalanıldı.

4. Uygun hiperparametrelerin seçilmesi modelin başarısını etkileyen en önemli unsurlardan biridir. Bu amaçla çapa kutularının boyut, oran ve aspect oranları için en uygun değerler aranmış, BB ler analiz edilerek verisetimize en uygun oranlar tespit edilmiş olup modele eklenmiştir.

5. Yine, alan bilgisinin modele eklenmesi yarışmacı adaylar arasındaki farkı belirleyecek en önemli özgün değer olacaktır. Bunun amaçla:

Mevcut patolojilerin 0 HU dan büyük ve 300 HU dan küçük olması gerektiği düşünülerek, önce tüm kesitlerin standart HU dağılımı hesaplanmış ardından bu değerler 0-255 HU arasına klip- lenmiştir.

B) Önümüzde kalan sürede yapmayı planladığımız özgünlük unsurları ise:

6. Daha güçlü ön bilgiler modele eklenebilir. Bu anatomik kısıtlılık şeklinde olabilir.

Bahsi geçen 6 patolojinin tümü farklı organ sistemlerine ait patolojilerdir.

Her organ sistemi spesifik bir anatomik yerleşimdedir. Bunun görüntüdeki karşılığı spesifik bir spatial lokasyonda yer alıyor olmasıdır.

7. Gerek z aksında gerekse x ve y akslarındaki pozisyon ek bir vektör olarak modele ön bilgi sağlamak aracılığı ile verilebilir.

8. Bu amaçla her kesiti ön ve arka olmak üzere y ekseninde 2 parçaya; ve sağ, orta ve sol olmak üzere x ekseninde 3 parçaya böleceğiz. Böylece her kesitten 6 ayrı yama elde edeceğiz.

Anatomi bilgimizi kullanarak nadir varyasyonlar dışında, apandisit, sağ arka, kolesistitin sağ ön, pankreatitin orta ön, abdominal aorta anevrizmasının orta arka, divertikülitin sol arka, ve nefro ve ürolitiazisin her daim arkada, sol ve sağ ile orta kesimin kesişme bölgelerinde olduğu bilgimizi modele vereceğiz.

9. Bunu yaparken ya modele giriş esnasında, oluşturduğumuz yamanın spatial kodunu vererek, ya görüntüyü bu şekilde hazırlanmış 6 ayrı yamaya bölüp her yamayı ayrı ayrı girdi olarak vererek, ya da tahmin sonucu üretilen sınıf değerinin spatial pozisyonunu olması gereken ile karşılaştırılıp uygunsuz bölgede olanlarının reddedilmesi şeklinde ön bilgi olarak ekleyerek modelimizi güçlendireceğiz. Bu şekilde şu ana kadar literatürde bilgimiz dahilinde radyo patoloji tespit problemlerinde bir örneği olmayan radyoloji bilgisinin modele eklenmesi sayesinde özgünleştirdiğimiz modelimizin başarımının artacağını düşünmekteyiz.

10. Farklı modellerin eğitilerek bunların BB tahminlerinin füzyonu şeklinde bir ensemble oluşturulmasıdır.

Sonuçlar ve İnceleme:

Modelimizi 2 ayrı senaryo ile test ettik. İlkinde 3D context bilgisi verilmeden, giriş aynı kesit 3 kere tekrarlanmak sureti ile verilerek, çapa boyut ve aspect oranlarında değişiklik yapılmaksızın orijinal implementasyonları uygulanarak, psödomaskler verilmeksizin, sistemin BB lerden kendi ürettiği otomatik maskler ile, eğitim ve test uygulanmıştır. Bu senaryoda HU değerlerinin 0-255 aralığına çekilmesi ve modelin autoencoder ile eğitilmiş ağırlıklarla başlatılması işlemleri yapılmıştır. Eğitim 10 katlı cross validasyon şemasına uygun olarak yapılmış olup her tur için sınıf başına accuracy değerleri ve mAP tablo halinde sunulmuştur.

Accuracy hesabı için IOU eşikleme değeri 0.5 olarak alınmıştır.

	Aorta	Apendisit	Kolesistit	Pankreatit	Divertikülit	Üriner	mAp
1	0.78	0.82	0.80	0.84	0.75	0.70	0.58
2	0.74	0.71	0.78	0.75	0.71	0.73	0.63
3	0.75	0.74	0.79	0.68	0.76	0.78	0.69
4	0.86	0.67	0.76	0.76	0.82	0.80	0.64
5	0.65	0.76	0.72	0.72	0.64	0.77	0.62
6	0.70	0.80	0.79	0.76	0.79	0.70	0.59
7	0.68	0.77	0.74	0.80	0.70	0.65	0.60
8	0.73	0.74	0.74	0.74	0.71	0.74	0.58
9	0.72	0.81	0.77	0.78	0.67	0.63	0.59
10	0.70	0.80	0.81	0.82	0.68	0.76	0.60

Tablo 4: Özel çapa oran ve büyüklükleri, 3D bağlam bilgisi, psödomask verilmeksizin

	Aorta	Apendisit	Kolesistit	Pankreatit	Divertikülit	Üriner	mAp
1	0.83	0.81	0.83	0.87	0.73	0.71	0.63
2	0.78	0.74	0.81	0.79	0.71	0.73	0.67
3	0.72	0.76	0.75	0.70	0.78	0.75	0.71
4	0.84	0.80	0.83	0.74	0.80	0.68	0.68
5	0.67	0.78	0.74	0.75	0.69	0.81	0.63
6	0.74	0.82	0.79	0.84	0.77	0.69	0.64
7	0.63	0.73	0.76	0.69	0.73	0.77	0.58
8	0.80	0.79	0.73	0.77	0.71	0.74	0.61
9	0.81	0.83	0.74	0.80	0.67	0.71	0.66
10	0.71	0.81	0.79	0.84	0.68	0.74	0.62

Tablo 5: Özel çapa oran ve büyüklükleri, 3D bağlam bilgisi, ve psödomask verilerek

Daha sonra temel katkılarımız olan özel çapa oran ve büyüklükleri, 3D bağlam bilgisi ve psödomask verilerek deneyler tekrarlanmıştır. Her iki deney de de 10 kat cross validasyon çalıştırılmış ve elde edilen değerler tabloda özetlenmiştir. İlk durumda mAP %61.2 den ikinci durumda %64.3 e çıkmıştır. mAP teki kazanç %3.2 dir. mAP tüm sınıflar için tüm IOU eşiklerinde ortalama kesinlik değerini yansıttığından obje tespit problemleri için evrensel bir metrik halini almıştır. Süremiz yetmediği için yaptığımız her adımın katkısının ne kadar olduğu ile ilişkili bir ablasyon çalışması gerçekleştirilememiştir. Ayrıca diğer eğitilmiş obje tespit ağları olan Detectron, nnDetection, YOLO ailesi, RetinaNet, DETR gibi mimariler ile farklı eğitilmiş backbone lar ile yapılması planlanan denemeler yapılamamıştır. Öte yandan anatomik priorların regresyonunun modele eklenmesi ve anatomi farkında yamalar ile eğitimin yapılması

işlemleri de henüz uygulanamamıştır. Bu işlemlerin modele olan pozitif katkıları beklenmektedir ve önümüzdeki süreçte tamamlanmaya çalışılacaktır.

Deney ve eğitim aşamalarında kullanılan veri setleri

LITS challenge ISBI 2017 and MICCAI 2017 kongrelerinde yarışmacılara sunulmuş bir veri setidir. 130 adet CT hacmi içerir (3). Görüntüler karaciğerdeki çeşitli yer, büyüklük ve etyolojideki tümörleri içerir. KITS veriseti ise böbrek tümörleri içeren bir verisetidir. 2019 da yayınlanan versiyonunda 210 CT hacmi içerir (4). Böreklerde çeşitli büyüklük dağılım ve etyolojiye sahip solid ve kistik lezyonları içerir. Bu veri-setleri eklenerek bir AE eğitilmiş ve modelin encoder kesiminin domain spesifik ağırlıkları öğrenmesi amaçlanmıştır. Ayrıca Teknofest'in yarışma kapsamında paylaştığı veriseti içinden her alt sınıf için 10 ar tane hastanın patolojileri segmente edilerek toplam 60 hastanın segmentasyon haritaları da ek olarak eğitimde kullanılmıştır.

Referanslar:

- [1] <https://www.slicer.org/>
- [2] https://github.com/matterport/Mask_RCNN
- [3] <https://github.com/PatrickChrist/LITS-CHALLENGE/blob/master/submission-guide.md>
- [4] <https://kits21.kits-challenge.org/>
- [5] He, Kaiming, Georgia Gkioxari, Piotr Dollr, and Ross Girshick. "Mask R-CNN." In ICCV, pp. 2961-2969. 2017.
- [6] Sheoran M, Dani M, Sharma M, Vig L. DKMA-ULD: Domain Knowledge augmented Multi-head Attention based Robust Universal Lesion Detection. arXiv:2203.06886 [cs.CV]
- [7] Yan, K., Wang, X., Lu, L., Summers, R.M.: DeepLesion: automated mining of large-scale lesion annotations and universal lesion detection with deep learning. Journal of Medical Imaging 5(3) (2018)
- [8] Lin, Tsung-Yi, Piotr Dollr, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection." In ICCV, pp. 2117-2125. 2017.
- [9] K. Yan, Bagheri M, and Summers R. 3d context enhanced region-based convolutional neural network for end-to-end lesion detection." In MICCAI, pp. 511-519. 2018.
- [10] K. Yan, Y. Tang, Y. Peng, V. Sandfort, M. Bagheri, Z. Lu, and R. M. Summers, "MULAN: Multitask Universal Lesion Analysis Network for Joint Lesion Detection , Tagging , and Segmentation," in *Proc. Int. Conf. MICCAI* 2019.

[11] Zlocha M, Dou Q and Glocker B. Improving Retina Net for CT lesion detection with dense masks from weak RECIST labels. In *International Conference on MICCAI*, pp 402–410

[11] Z. Li, S. Zhang, J. Zhang, K. Huang, Y. Wang, and Y. Yu, “MVP- Net: Multi-view FPN with Position-aware Attention for Deep Universal Lesion Detection,” in *Proc. Int. Conf. Med. Image Comput. Computer- Assisted Intervent.*, 2019.

[12] Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sunar. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks arXiv:1506.01497 [cs.CV]

