

TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için

Hastalık Tespiti Kategorisi)

PROJE DETAY RAPORU

TAKIM ADI: AIDEO



İçindekiler

Proje Mevcut Durum Değerlendirmesi	1
Özgünlük	3
Data Augmentation (Veri Artırımı):	3
Ensemble Learning (Topluluk Öğrenimi):	4
Dönüştürücü (Transformer) Modeller:	4
Image Preprocessing (Görüntü Ön İşleme):	4
Sonuçlar ve İnceleme	5
Test Senaryoları:	5
Deney Ortamı:	6
Kalite Kontrolleri:	6
Eğitim Seti İstatistikleri:	6
Validasyon Metrikleri:	7
Deney ve eğitim aşamalarında kullanılan veri setleri	8
T.C Sağlık Bakanlığı- Sağlık Bilgi Sistemleri Genel Müdürlüğü Verileri	8
AbdomenCT-1K	8
CT KIDNEY DATASET	9
Referanslar	9



1. Proje Mevcut Durum Değerlendirmesi

Projenin mevcut durumu Proje Sunuş Raporunda çizilen çerçeveye uygun şekilde gitmektedir. Problemin doğası, veri setinin büyüklüğü ve eldeki kaynakların yeniden değerlendirilmesi sonucu ufak çaplı revizyonlar yapılmıştır. Bu değişiklikler aşağıdaki başlıklar altında incelenecektir:

- **Problem Tanımı ve Çözüm Yaklaşımları:**

Proje Sunuş Raporunda öngörülen çözümün -Object Detection (Nesne Tespiti)- verilen veri setinin incelenmesi sonucu isabetli olduğu saptanmış ve raporda sunulan algoritmalar (ResNet[0], R-CNNs[1], YOLO[2], RetinaNet[3], DETR[4]) üzerinden baseline model eğitimleri başlamıştır. Baseline model deneyleri sırasında problemin ve veri setinin yapısı incelendiğinde You Only Look Once: Unified, Real-Time Object Detection (YOLO)[2], diğer algoritmalarından daha öne çıkmış ve alınan sonuçlar da bunu doğrular nitelikte görülmüştür. Yapılan deneylerde Transformer[11] bazlı mimarilerin de umut verici sonuçları saptanmış ve gelecek detaylı deneylerde kullanılmasına karar verilmiştir.

- **Eğitim Donanımı ve Arayüzler:**

Proje Sunuş Raporunda kullanılması planlanan Google Cloud üzerindeki sunucular yerine yine Google'ın çevrimiçi makina öğrenme platformu olan Google Colab tercih edilmiştir. bunun başlıca sebebi eldeki kaynakların Cloud platform ücretlendirmeleri ile karşılaştırılmasıdır. Colab üzerinde GPU olarak genellikle NVIDIA Tesla P100 GPU ve T4 modelleri kullanılmıştır. Deney ortamları ise yine Python üzerinden hızlı prototipleme amacıyla Jupyter Lab ortamında ve PyTorch framework'ü üzerinden ilerletilmiştir.

- **Mimari Yapılar ve Özgünlük**

Bir sonraki ana başlık altında da inceleneceği gibi Proje Sunuş Raporunda belirtilen birçok özgün teknik, deney aşamasında başarı ile uygulanmıştır; fakat raporda denenmesi öngörülen segmentasyon tabanlı nesne tespiti algoritmaları sunulan veri setinin etiket formatı (PASCAL VOC)[5] ve veri seti büyüklüğü (~38.000 görsel) göz önüne alındığında piksel bazında işaretlemenin eldeki imkanlarla gerçekleştirilmesinin çok uzun süre alacağından Mask R-CNN[6] gibi modeller deney dışı bırakılmıştır.

Yukarıdaki başlıklar altında toplanan revizyonlar haricinde proje belirlenen takvim ile paralel şekilde ilerlemektedir ve izlenen adımlar kabaca şöyle sıralanabilir:

- Sunulan Excel dosyası üzerinden pandas, matplotlib, seaborn vb. kütüphaneler yardımı ile Keşifsel Veri Analizi yapıldı ve elde edilen bulgular teknik şartname ışığında deneylere yansıtıldı.

- DICOM formatındaki kesitler pydicom kütüphanesi yardımıyla NumPy arraylarına dönüştürüldü ve bazı ekstra ön işlemler uygulanarak .png formatındaki dijital görsellere dönüştürüldü.
- Kullanılacak frameworkler ve eldeki veri setine bağlı olarak yeni bir veri yapısı şeması düzenlendi.
- Yapılan incelemeler (Veri yapısı, dağılımı, formatı vs.) sonucunda problem tanımı tekrar gözden geçirildi ve temel deneyler için öncelikli seçilecek algoritmalar belirlendi. Bu algoritmalar hakkında eldeki yeni veriler ışığında yeniden literatür taraması yapıldı ve çeşitli düzenlemeler uygulandı.
- Algoritmaların ihtiyaçlarına göre veri yapıları ve etiket formatları model eğitimleri için yeniden düzenlendi.
- Problem ihtiyaçlarına göre en genellenebilir eğitim metrikleri teknik şartnamede belirtilen metriklere (F-1 ve IoU) göre seçildi ve eğitim sonuçları bu kıstasa göre değerlendirildi.
- Yapılan veri analizi ışığında train ve test splitleri çeşitli yöntemlerle gerçeğe yakınsayacak şekilde dağıtıldı.
- Deney sonuçlarının tekrar üretilebilir ve bir arada izlenebileceği deney takip ortamı oluşturuldu.
- Deney sonuçlarının incelenmesine bağlı olarak iteratif şekilde yeni yöntemler eklendi veya çalışmayan kısımlar çıkarıldı.
- Yarışma final gününe kadar izlenecek program belirlendi ve bu süreçte gelecek deneylerin prototipleri oluşturuldu.

Proje Sunuş Raporunda öngördüğümüz takvimin tamamlanan kısımlarının kırmızıyla işaretlenmiş mevcut hali aşağıdaki gibidir:


	Sprint Başlangıç Sprint Bitiş	01.04 15.04	15.04 01.05	01.05 15.05	15.05 01.06	01.06 15.06	15.06 01.07	01.07 15.07	15.07 31.07
Şablonların ve şartnamelerin incelemesi									
Akademik literatür taraması									
Verinin incelenmesi									
Veri çoğaltma türlerinin kararlaştırılması									
Baz modellerin kararlaştırılması									
Örnek bir akış kurgulanarak prototipleme									
Farklı modeller ile prototipleme									
Birleştirilecek modellere karar verilmesi									
Model hiper parametre optimizasyonu									
Yarışma scriptinin hazırlanması									

2. Özgünlük

2.1.Data Augmentation (Veri Artırımı):

Proje Sunuş Raporunda da belirtildiği gibi artan veri sayısı birçok durumda derin öğrenme ağlarının performansını yükseltmektedir.[7] Bir önceki raporda belirtilen birçok yöntem başarı ile uygulanmıştır. Görsellerin piksel bazında dönüştürülmesinin (bulanıklaştırma, keskinleştirme, parlaklaştırma, karartma vs.) yanında görseller üstünde yakınlaştırma, uzaklaştırma, yönünü değiştirme, şeklini bozma gibi görselin bütününe veya daha büyük parçalarını etkileyen transformasyonlar da eklenmiştir.

Ayrıca yine eğitim sırasında görsel üstünde daha kompleks, modelleri zorlayıcı ve dolayısıyla modellerin eğitim setini ezberlemesini (overfit) engelleyen başka yöntemler de uygulanmıştır. Bunlar başlıca mozaikleştirme (birkaç görseli grid halinde bir araya getirme)[8], copy-paste (bir görseldeki ilgi alanının başka bir eğitim görselinin içine eklenmesi)[9], MixUp (farklı görsellerin daha saydam şekilde iç içe geçirilmesi)[9] olarak sıralanabilir. Bu yöntemler eğitim sırasında belirli olasılıklarla rastgele şekilde görsellere uygulanmaktadır. Aşağıdaki 16'lık bir eğitim batch'ının üzerinde uygulanan yöntemlerin örnekleri görülebilir:




2.2.Ensemble Learning (Topluluk Öğrenimi):

Proje Sunuş Raporunda da bahsedildiği gibi bu yöntem ile birkaç tane görece daha zayıf öğrenen modelin bir araya gelerek daha güçlü bir tahminde bulunması sağlanmaktadır.[10] Bu tahminler genelde tek başına iyi sonuçlar veren tekil modellerden çok daha genellenebilir çıktılar vermektedirler.

Deneyler sırasında model bazında farklı mimarilerin birleştirilmesi yoluyla yapılan tahminlemelerin alınan ilk sonuçlarının tekil modellere göre daha başarılı olduğu doğrulanmıştır. Farklı mimarilerinin birleştirilmesinin yanında aynı mimarinin farklı görsel büyüklüklerinde eğitilmesi ile modellerin çeşitli görsel büyüklüklerinde istenen ilgi alanını saptamayı başarabildiği durumların da topluluk öğrenimi aşamasında yakalanması hedeflenmiştir.

2.3.Dönüştürücü (Transformer) Modeller:

Son yıllarda özellikle Doğal Dil İşleme (Natural Language Processing) alanında büyük başarılar yakalayan Dikkat (Attention) Mekanizması[11] temelli mimariler yakın zamanda bilgisayarlı görü alanında nesne tespit problemlerini çözme konusunda da başarılı sonuçlar vermeye başlamıştır. Bu mekanizma model girdilerinin belli bölgelerine daha seçici olarak odaklanmakta ve daha etkin bir şekilde öğrenme sağlamaktadırlar.




Bu amaçla YOLOS (You Only Look at One Sequence)[12] mimarisi üzerinde deneyler devam etmektedir. Özellikle Huggingface kütüphanesinin bu mimari özelindeki implementasyonu umut verici sonuçlar göstermektedir.

2.4.Image Preprocessing (Görüntü Ön İşleme):

Yapılan veri analizi sırasında fark edilen, farklı marka cihazların ürettiği DICOM görsellerinin array haline çevrilmesi sırasında yaşanan piksel farklılıklarının marka bağımsız hale getirilmesi için tüm görsellere “Modality LUT” uygulandı. Bu yöntemle her görsel için piksel değerleri 0-255 arası standartlaştırıldı ve modellerin daha rahat işleyebileceği formatlara getirildi. Görseller üzerine Modality LUT işleminin ardından VOI (Values of Interest) LUT işlemi de uygulanarak numpy arraylarından oluşturulan görsellerin daha

kullanıcı dostu bir hale getirilmesi sağlandı ve model eğitimi sırasında gözle yapılan kalite kontrolleri daha rahat bir hale getirildi.




Ön işlem öncesi örnek görsel (Solda) ve Ön işlem sonrası örnek görsel (Sağda)

3. Sonuçlar ve İnceleme

3.1.Test Senaryoları:

Metriklere geçmeden önce eğitim sonuçları iki tip test çerçevesinde değerlendirildi. İlk senaryoda final aşaması test kesitlerinin mevcut eğitim setinde koordinatların verilmediği ara kesitlerden alınacağı öngörüldü. Bu durumda Çapraz Doğrulama (Cross Validation) validasyon setleri tüm sınıfların eğitim setiyle benzer mertebede temsil edilmesi gerektiği varsayılarak Stratified (Tabakalı) Örnekleme kullanıldı. Bu dağılımla eğitilen modeller benzer örnekler görebildiklerinden ötürü yüksek validasyon metriklerine ulaşılar.

İkinci senaryo ise gerçek hayat kullanımına daha uygun ve modellerin daha önce hiç görmediği hasta görüntüleri üzerinden skorlanması ile gerçekleştirildi. Bu senaryoda eğitim ve validasyon setleri arasında hiçbir hasta kesişimi olmamasına özen gösterildi ve bu limitasyon çerçevesinde sınıf dağılımları birinci senaryoya benzer şekilde olabildiğince dengeli şekilde dağıtıldı. Bu işlem için sklearn kütüphanesinin StratifiedGroupKFold fonksiyonu kullanıldı. Bu yöntemle gerçekleştirilen validasyonlarda metriklerde gözle görülür düşüşler yaşansa da deney sonuçlarının daha güvenilir olduğu kanısına varıldı.



3.2.Deney Ortamı:

Tüm deneylerin çıktıları tek bir ortam üzerinden takip edildi ve böylece sonuçların devamlılığı ve geriye dönük analizlerin yapılabilmesi sağlandı. Bu deney takip ortamı için Weights&Biases platformu seçildi.


3.3.Kalite Kontrolleri:

Deneyler öncesi verinin sağlığını ölçmek üzere veri analizinin yanında çeşitli incelemeler yapıldı. Bu incelemelerde MMB'lerin 24 tanesinin eş (duplicate), yani bir veya birden fazlasının aynı koordinatlar üzerinde olduğu saptandı ve bunlar temizlendi. Yine bu sırada 3 adet MMB koordinatının görsellerin dışına taştığı gözlemlendi ve bu örnekler deney setlerinin dışında tutuldu.

Sınıflar teknik şartnamede belirtilen ihtiyaçlar doğrultusunda incelendi ve Kalsifiye Divertikül ve Apendikolit gibi az sayıda (sırasıyla 359 ve 75) örneği olan sınıflar eğitim seti dışında tutuldu. Safra Kesesi Taşları ise Böbrek ve Üreter taşlarının model tarafından bu örneklerle karıştırılmaması için ayrı bir sınıf olarak eklendi.


3.4.Eğitim Seti İstatistikleri:

Yapılan incelemeler sonucu sınıf dağılımlarının eşit olmadığı gözlemlendi, bu durumun yol açabileceği sorunlar (Class Imbalance)[13] eğitim sırasında göz önünde bulunduruldu. Görsellerdeki ilgi konusu alanların görece daha sağlıklı dağıldığı fakat bazı uç durumların göz önünde bulundurulması gerektiği not edildi.




3.5.Validasyon Metrikleri:

Senaryo-1'deki (Karma olgu kesiti ayrılmış kümeler) baseline model sonuçları aşağıdaki gibidir:




Bu senaryoda yüksek seviyelerde Kesinlik ve Duyarlılık skorları elde edilirken 0.5 IoU eşliğinde Ortalama Hassasiyet (Mean Average Precision) %90 üzeri seviyeleri görmüştür. Yine 0.5'ten 0.95'e kadar kademeli olarak artan IoU eşiklerinin ortalamasında %56 AP'nin üzerine çıkmıştır. Fakat daha önceki kısımlarda bahsedilen sebeplerden ötürü bu test sonuçlarının her ne kadar iyi olsalar da overfit durumundan etkilenmiş olabilecekleri varsayılmış ve daha güvenilir Senaryo-2 test çerçevesi oluşturulmuştur.

Senaryo-2'deki (Olgu bazında kesişmeyen test kümesi) baseline model sonuçları ise:



Yukarıdaki grafikte çeşitli güven eşiklerinde baseline modelin sınıf bazında F-1 skorları gözükmektedir. (0.6 IoU Threshold) burada modelin hangi sınıflarda daha başarılı veya başarısız olduğu gözlemlenebilir.



İkinci senaryoda ilkinde göre daha düşük Kesinlik ve Duyarlılık skorları elde edilirken 0.6 IoU eşliğinde Ortalama Hassasiyet (Mean Average Precision) %68 civarı seviyeleri görmüştür. Yine 0.5'ten 0.95'e kadar kademeli olarak artan IoU eşiklerinin ortalamasında %29 AP skoru elde edilmiştir. Bu yöntemin tarafımızca gerçek hayat senaryolarında daha başarılı sonuçlar vereceği düşünülmektedir.

Teknofest Sağlıkta Yapay Zeka finali özelinde seçilecek senaryo bu rapor sonrası yapılacak daha detaylı testler sonucunda ve final gününde kararlaştırılacaktır.

4. Deney ve eğitim aşamalarında kullanılan veri setleri

- **T.C Sağlık Bakanlığı- Sağlık Bilgi Sistemleri Genel Müdürlüğü Verileri**

Yarışmacılara sağlanan ve karın ağrısı şikayeti ile acil servis başvurusu yapılmasına neden olan 6 farklı klinik durum ile ilgili karın bölgesine yönelik çekilen ilaçlı veya ilaçsız bilgisayarlı tomografi serilerini içeren datasetidir. Bu dataset deneylerin başlangıcında yeterli gözükmekle beraber içerdiği az sayıdaki negative sample olarak kullanılabilecek sağlıklı birey görüntülerinden ötürü yeni dataset arayışına girilmiştir.

- **AbdomenCT-1K**

Karaciğer, böbrek, dalak ve pankreas dahil olmak üzere karın bölgesinde bulunan organların 1000'den fazla bilgisayarlı tomografilerini içeren organ segmentasyon verileridir.[14] Bu dataseti ekleme amacı daha önce de bahsedildiği gibi içerdiği sağlıklı birey görüntüleridir. Dataset içerisinde var olan hastalıklı tomografiler

(Tümör) çıkarılıp kullanıma uygun hale getirilmiştir. Eklenen sağlıklı birey görsellerinin eğitim aşamasında modellerin converge olmasına fayda sağladığı görülmüştür.

● CT KIDNEY DATASET

PACS (Picture archiving and communication system) yardımıyla Dhaka, Bangladeş'te bulunan hastanelerden böbrek tümörü, kisti, taşı teşhis edilmiş hastalardan veya sağlıklı bireylerden toplanan bilgisayarlı tomografi görüntülerini içeren datasetidir.[15] Dataset içerisinde sadece sağlıklı bireylerden toplanan bilgisayarlı tomografi görüntüleri veri setimize eklenmiş olup yapılacak deneyler ile böbrek taşları içeren tomografi görüntülerinin modele etkisi ölçülecek ve bu ölçümler sonucu veri setimize eklenip eklenmeyeceğine karar verilecektir.

5. Referanslar

- [0] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, Deep Residual Learning for Image Recognition, arXiv:1512.03385, 2015
- [1] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik, Rich Feature hierarchies for accurate object detection and semantic segmentation, arXiv:1311.2524, 2013
- [2] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi, You Only Look Once: Unified, Real-Time Object Detection, arXiv:1506.02640, 2015
- [3] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, Piotr Dollár, Focal Loss for Dense Object Detection, arXiv:1708.02002, 2017
- [4] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, Sergey Zagoruyko, End-to-End Object Detection with Transformers, arXiv:2005.12872, 2020
- [5] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn, and Andrew Zisserman. The pascal visual object classes (voc) challenge. In IJCV, 2010
- [6] Kaiming, He, Georgia Gkioxari, Piotr Dollár, Ross Girshick, Mask R-CNN, arXiv:1703.06870, 2017
- [7] Luis Perez, Jason Wang, The Effectiveness of Data Augmentation in Image Classification using Deep Learning, arXiv:1712.04621, 2017
- [8] Alexey Bochkovskiy, Chien-Yao Wang, Hong-Yuan Mark Liao, YOLOv4: Optimal Speed and Accuracy of Object Detection, arXiv:2004.10934, 2020
- [9] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, David Lopez-Paz, mixup: Beyond Empirical Risk Minimization, arXiv:1710.09412, 2017
- [10] Angela Casado-Garcia and Jonathan Heras, Ensemble Methods for Object Detection, UNIRIOJA Joheras, 2019
- [11] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin, Attention Is All You Need, arXiv:1706.03762, 2017
- [12] Yuxin Fang, Bencheng Liao, Xinggang Wang, Jiemin Fang, Jiyang Qi, Rui Wu, Jianwei Niu, Wenyu Liu, You Only Look at One Sequence: Rethinking Transformer in Vision through Object Detection, arXiv:2106.00666, 2021
- [13] K. Oksuz, B. C. Cam, S. Kalkan, E. Akbas, "Imbalance Problems in Object Detection: A Review", Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2020
- [14] J. Ma et al., 'AbdomenCT-1K: Is Abdominal Organ Segmentation A Solved Problem?' arXiv, 2020.
- [15] kaggle.com/datasets/nazmul0087/ct-kidney-dataset-normal-cyst-tumor-and-stone